

**BỘ CÔNG THƯƠNG
ĐẠI HỌC CÔNG NGHIỆP HÀ NỘI**



BÁO CÁO BÀI TẬP LỚN

HỌC PHẦN: DỰ BÁO VÀ PHÂN TÍCH DỮ LIỆU

ĐỀ TÀI

**ỨNG DỤNG MÔ HÌNH KẾT HỢP ARIMA – XGBOOST TRONG DỰ
BÁO GIÁ CỔ PHIẾU JOLLIBEE FOODS CORPORATION**

Giảng viên hướng dẫn: ThS. Trương Hoàng Giang

Lớp: 20251AA6061001

Nhóm: No.1

Sinh viên thực hiện:

1. Nguyễn Tùng Lâm – 2022601079
2. Nguyễn Như Quỳnh – 2022602213
3. Đỗ Thị Thùy Linh – 2022605105
4. Đàm Mạnh Dũng – 2022600921
5. Tạ Diễm Quỳnh – 2023601191

Hà Nội, tháng 12 năm 202

LỜI CẢM ƠN

Nhóm em xin bày tỏ lòng biết ơn sâu sắc tới ThS. Trương Hoàng Giang – giảng viên Khoa Kinh doanh Số, Trường Kinh tế - Đại học Công nghiệp Hà Nội, người đã tận tình hướng dẫn, truyền đạt kiến thức chuyên môn và đồng hành cùng nhóm em trong suốt quá trình thực hiện đề tài. Những chỉ dẫn kịp thời và định hướng quý báu của thầy là nền tảng quan trọng giúp nhóm em vượt qua nhiều khó khăn và hoàn thành báo cáo.

Nhóm em xin trân trọng cảm ơn Ban Giám hiệu cùng toàn thể quý thầy cô Đại học Công nghiệp Hà Nội đã tạo điều kiện thuận lợi về môi trường học tập, nghiên cứu và hỗ trợ để nhóm em có thể triển khai và hoàn thiện đề tài.

Báo cáo được thực hiện trên cơ sở tham khảo nhiều công trình nghiên cứu, sách và tài liệu chuyên ngành có liên quan, qua đó giúp nhóm em tiếp cận vấn đề một cách khoa học và gần với thực tiễn.

Mặc dù đã có nhiều cố gắng, song do hạn chế về thời gian, kiến thức và kinh nghiệm, báo cáo khó tránh khỏi những thiếu sót. Nhóm em rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô để báo cáo được hoàn thiện hơn.

Nhóm em xin chân thành cảm ơn!

MỤC LỤC

LỜI CẢM ƠN	1
MỤC LỤC	2
DANH MỤC HÌNH ẢNH	5
DANH MỤC BẢNG	5
PHẦN 1: GIỚI THIỆU (INTRODUCTION)	6
1.1. TÍNH CẤP THIẾT CỦA ĐỀ TÀI.....	6
1.1.1. Vai trò của thị trường chứng khoán và thách thức trong công tác dự báo	6
1.1.2. Jollibee Foods Corporation và bài toán định giá trong ngành F&B	7
1.1.3. Khoảng trống phương pháp luận.....	9
1.2. MỤC TIÊU NGHIÊN CỨU	10
1.2.1. Mục tiêu tổng quát.....	10
1.2.2. Mục tiêu cụ thể	10
1.3. CÂU HỎI NGHIÊN CỨU	11
1.4. ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU	11
1.4.1. Đối tượng nghiên cứu.....	11
1.4.2. Phạm vi dữ liệu.....	12
1.4.3. Phạm vi nội dung.....	12
1.5. Ý nghĩa khoa học và thực tiễn.....	12
1.6. CẤU TRÚC BÁO CÁO	14
PHẦN 2. CƠ SỞ LÝ LUẬN VÀ TỔNG QUAN NGHIÊN CỨU (LITERATURE REVIEW)	15
2.1. LÝ THUYẾT NỀN TẢNG VỀ DỰ BÁO CHUỖI THỜI GIAN TÀI CHÍNH ..	15
2.1.1. Khái niệm và Đặc trưng của Chuỗi thời gian Tài chính	15
2.1.2. Tính dừng (Stationarity) và Kiểm định Nghiệm đơn vị	16
2.1.3. Giả thuyết Bước đi ngẫu nhiên (Random Walk Hypothesis).....	17

2.2. MÔ HÌNH ARIMA (AUTOREGRESSIVE INTEGRATED MOVING AVERAGE).....	18
2.2.1. Cấu trúc mô hình	18
2.2.2. Quy trình Box-Jenkins.....	19
2.2.3. Ưu điểm và Hạn chế.....	20
2.3. MÔ HÌNH XGBOOST (EXTREME GRADIENT BOOSTING).....	20
2.3.1. Giới thiệu thuật toán.....	20
2.3.2. Cơ chế hoạt động và Hàm mục tiêu	21
2.3.3. Lý do lựa chọn XGBoost cho dữ liệu tài chính.....	22
2.4. MÔ HÌNH LAI (HYBRID MODEL) VÀ LÝ THUYẾT PHÂN RÃ SAI SỐ....	22
2.4.1. Cơ sở lý thuyết của Phương pháp Lai ghép	22
2.4.2. Tổng quan các nghiên cứu thực nghiệm	24
2.4.3. Khoảng trống nghiên cứu (Research Gap).....	25
PHẦN 3. PHƯƠNG PHÁP NGHIÊN CỨU (METHODOLOGY)	27
3.1. KHUNG PHÂN TÍCH ĐỀ XUẤT (PROPOSED FRAMEWORK).....	27
3.2. THU THẬP VÀ XỬ LÝ DỮ LIỆU	27
3.2.1. Nguồn dữ liệu và Phạm vi.....	27
3.2.2. Kỹ thuật Tiền xử lý (Data Preprocessing).....	28
3.3. GIAI ĐOẠN 1: MÔ HÌNH HÓA TUYẾN TÍNH VỚI ARIMA	29
3.3.1. Kiểm định tính dừng (Stationarity Test)	29
3.3.2. Lựa chọn tham số cấu trúc (Model Selection)	29
3.3.3. Trích xuất Phần dư (Residual Extraction).....	30
3.4. GIAI ĐOẠN 2: MÔ HÌNH HÓA PHI TUYẾN VỚI XGBOOST	31
3.4.1. Kỹ thuật đặc trưng (Feature Engineering).....	31
3.4.2. Tối ưu hóa Cửa sổ thời gian (Window Size Optimization)	32
3.5. CƠ CHẾ DỰ BÁO ĐỆ QUY (RECURSIVE FORECASTING).....	32
3.6. TIÊU CHÍ ĐÁNH GIÁ (PERFORMANCE METRICS).....	33
3.7. CÔNG CỤ VÀ MÔI TRƯỜNG NGHIÊN CỨU	35

PHẦN 4. EMPIRICAL RESULTS – KẾT QUẢ THỰC NGHIỆM	36
4.1. PHÂN TÍCH DỮ LIỆU SƠ BỘ (EXPLORATORY DATA ANALYSIS - EDA)	36
4.1.1. Hành vi giá và xu hướng	36
4.1.2. Kiểm định nghiệm đơn vị (ADF Test)	37
4.1.3. Phân tích Tự tương quan (ACF và PACF)	38
4.2. KẾT QUẢ MÔ HÌNH ARIMA	39
4.2.1. Ước lượng tham số tối ưu	39
4.2.2. Đánh giá phần dư (Residual Analysis)	40
4.3. KẾT QUẢ MÔ HÌNH LAI (HYBRID MODEL)	45
4.3.1. Tối ưu hóa Window Size cho XGBoost	45
4.3.2. Hiệu quả "Sửa sai" của Mô hình Lai	46
4.4. SO SÁNH HIỆU QUẢ DỰ BÁO (COMPARATIVE ANALYSIS)	48
4.5. DỰ BÁO TUƠNG LAI	49
4.5.1. Nhận định xu hướng và Hành động giá	49
4.5.2. Phân tích diễn biến chi tiết	50
PHẦN 5. CONCLUSION – KẾT LUẬN VÀ HÀM Ý QUẢN TRỊ	52
5.1. Kết luận về Hiệu quả Mô hình	52
5.2. Hàm ý Quản trị và Khuyến nghị	53
5.3. HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN (LIMITATIONS & FUTURE WORKS)	54
TÀI LIỆU THAM KHẢO	56
PHỤ LỤC	59

DANH MỤC HÌNH ẢNH

Hình 3. 1 Biểu đồ ACF và PACF của chuỗi sai phân giá đóng cửa	30
Hình 4. 1 Biểu đồ giá đóng cửa cổ phiếu Jollibee theo thời gian	37
Hình 4. 2 Biểu đồ ACF và PACF của chuỗi sai phân giá đóng cửa	39
Hình 4. 3 Biểu đồ nghiệm nghịch đảo của các đa thức ARIMA	41
Hình 4. 4 Biểu đồ so sánh giá đóng cửa thực tế và giá dự báo của mô hình ARIMA(1,1,1).	44
Hình 4. 5 Biểu đồ so sánh giá thực tế và giá dự báo trong 10 ngày gần nhất của mô hình ARIMA(1,1,1).	44
Hình 4. 6 Biểu đồ tương quan giữa Window Size và Sai số (RMSE)	45
Hình 4. 7 Biểu đồ kết quả mô hình lai: Dự báo giá cổ phiếu Jollibee trong 30 ngày tới	47
Hình 4. 8 Biểu đồ so sánh sai số RMSE	49
Hình 4. 9 Biểu đồ kết quả mô hình lai: Dự báo giá cổ phiếu Jollibee trong 10 ngày tới	50

DANH MỤC BẢNG

Bảng 4. 1 Kết quả kiểm định ADF cho giá đóng cửa cổ phiếu Jollibee	37
Bảng 4. 2 Kết quả kiểm định ADF cho chuỗi sai phân giá đóng cửa cổ phiếu Jollibee	38
Bảng 4. 3 Kết quả bộ tham số bằng phương pháp tìm kiếm sử dụng auto_arima	40
Bảng 4. 4 Kết quả kiểm định ADF cho phần dư của mô hình ARIMA(1,1,1)	43
Bảng 4. 5 Kết quả kiểm định Ljung-Box cho phần dư của mô hình ARIMA(1,1,1)	43
Bảng 4. 6 Kết quả so sánh hiệu quả dự báo các mô hình	48
Bảng 4. 7 Chi tiết giá dự báo 10 ngày tới (USD)	51

PHẦN 1: GIỚI THIỆU (INTRODUCTION)

1.1. TÍNH CẤP THIẾT CỦA ĐỀ TÀI

1.1.1. Vai trò của thị trường chứng khoán và thách thức trong công tác dự báo

Trong bối cảnh kinh tế số phát triển mạnh mẽ và quá trình toàn cầu hóa tài chính ngày càng sâu rộng, thị trường chứng khoán giữ vai trò trung tâm trong hệ thống tài chính của mỗi quốc gia. Không chỉ là kênh huy động vốn dài hạn cho doanh nghiệp và Chính phủ, thị trường chứng khoán còn phản ánh kỳ vọng của nhà đầu tư đối với tăng trưởng kinh tế, môi trường vĩ mô và triển vọng của từng ngành. Do đó, diễn biến của giá cổ phiếu thường được xem là một chỉ báo quan trọng phản ánh trạng thái và mức độ ổn định của nền kinh tế. Đối với các chủ thể tham gia thị trường, từ các định chế tài chính lớn đến nhà đầu tư cá nhân, khả năng dự báo xu hướng biến động giá cổ phiếu có ý nghĩa thiết thực trong việc ra quyết định đầu tư, tối ưu hóa lợi nhuận và kiểm soát rủi ro danh mục (Fama, 1970).

Tuy nhiên, việc dự báo giá cổ phiếu là một bài toán khó, xuất phát từ bản chất phức tạp của chuỗi thời gian tài chính. Giá cổ phiếu chịu tác động đồng thời của nhiều yếu tố, bao gồm thông tin doanh nghiệp, điều kiện kinh tế vĩ mô, chính sách tiền tệ, cũng như hành vi và kỳ vọng của nhà đầu tư. Theo Giả thuyết Thị trường Hiệu quả (Efficient Market Hypothesis – EMH), mọi thông tin sẵn có đều đã được phản ánh đầy đủ vào giá, khiến cho biến động giá mang tính ngẫu nhiên và khó dự đoán nếu chỉ dựa trên dữ liệu quá khứ (Fama, 1970). Trong khuôn khổ lý thuyết này, việc xây dựng các mô hình dự báo có khả năng tạo ra lợi nhuận vượt trội so với thị trường được xem là không khả thi trong dài hạn.

Mặc dù vậy, nhiều nghiên cứu thuộc lĩnh vực Tài chính Hành vi cùng với các bằng chứng thực nghiệm trong những thập kỷ gần đây đã đặt ra những nghi vấn đối với giả định thị trường hoàn toàn hiệu quả. Các yếu tố tâm lý như sự quá tự tin, hành vi bầy đàn hay phản ứng chậm trước thông tin mới có thể dẫn đến sự sai lệch tạm thời giữa giá thị

trường và giá trị nội tại của cổ phiếu. Bên cạnh đó, sự tồn tại của các chu kỳ kinh tế, chu kỳ ngành và các hiệu ứng theo mùa cho thấy dữ liệu giá cổ phiếu có thể chứa đựng những mẫu hình phi tuyến và có tính lặp lại, tạo điều kiện cho việc áp dụng các phương pháp phân tích và dự báo nâng cao.

Đối với các thị trường mới nổi, đặc biệt là tại khu vực Đông Nam Á, những đặc điểm trên càng trở nên rõ nét. Thị trường chứng khoán tại các quốc gia này thường có mức độ biến động cao, thanh khoản chưa đồng đều và chịu ảnh hưởng mạnh từ dòng vốn quốc tế. Chuỗi dữ liệu giá vì vậy thường mang tính không dừng, nhiễu lớn và dễ bị tác động bởi các cú sốc ngoại sinh. Những sự kiện như thay đổi chính sách lãi suất của Cục Dự trữ Liên bang Mỹ (Fed), biến động tỷ giá, hay căng thẳng địa chính trị có thể dẫn đến các biến động đột ngột trong ngắn hạn, làm gia tăng rủi ro và thách thức đối với các mô hình định lượng truyền thống vốn dựa trên các giả định tuyến tính và ổn định.

Trong bối cảnh đó, nhu cầu nghiên cứu và ứng dụng các phương pháp dự báo linh hoạt hơn, có khả năng nắm bắt đặc điểm phi tuyến và biến động của chuỗi thời gian tài chính, ngày càng trở nên cấp thiết. Việc kết hợp giữa các tiếp cận kinh tế lượng truyền thống và các phương pháp học máy hiện đại được kỳ vọng sẽ góp phần cải thiện độ chính xác dự báo, đồng thời cung cấp thêm cơ sở khoa học cho quá trình ra quyết định đầu tư trong điều kiện thị trường nhiều bất định.

1.1.2. Jollibee Foods Corporation và bài toán định giá trong ngành F&B

Trong bối cảnh nghiên cứu nêu trên, cổ phiếu của Jollibee Foods Corporation (JFC), với mã giao dịch quốc tế JBFCF, được lựa chọn làm đối tượng nghiên cứu điển hình. Jollibee là một trong những doanh nghiệp tiêu biểu của Philippines trong lĩnh vực dịch vụ thực phẩm (F&B), đồng thời là tập đoàn có tốc độ mở rộng nhanh tại khu vực châu Á. Với mạng lưới khoảng 6.900 cửa hàng hoạt động tại nhiều quốc gia và doanh thu đạt mức cao nhất từ trước đến nay là 244,1 tỷ PHP vào năm 2023 (Jollibee Foods Corporation, 2024), cổ phiếu JFC thường được xếp vào nhóm cổ phiếu vốn hóa lớn

(blue-chip) trong ngành tiêu dùng, thu hút sự quan tâm đáng kể của cả nhà đầu tư trong nước và quốc tế.

Tuy nhiên, diễn biến giá cổ phiếu JFC trong giai đoạn 2024–2025 cho thấy đây không phải là một tài sản có xu hướng ổn định. Dữ liệu giao dịch cho thấy giá cổ phiếu chịu tác động đồng thời của các yếu tố tích cực đến từ nội tại doanh nghiệp và những áp lực từ môi trường kinh tế vĩ mô. Về phía doanh nghiệp, quá trình phục hồi mạnh mẽ của hoạt động kinh doanh sau đại dịch COVID-19, cùng với chiến lược mở rộng hệ thống cửa hàng ra thị trường quốc tế, đã tạo ra kỳ vọng tăng trưởng dài hạn và đóng vai trò là động lực hỗ trợ giá cổ phiếu. Ngược lại, trong cùng giai đoạn này, doanh nghiệp cũng phải đối mặt với những thách thức đáng kể từ bên ngoài, bao gồm áp lực lạm phát đối với chi phí nguyên vật liệu đầu vào và sự thay đổi trong khẩu vị rủi ro của dòng vốn ngoại trước bối cảnh lãi suất toàn cầu duy trì ở mức cao.

Sự tồn tại đồng thời của các yếu tố hỗ trợ và bất lợi đã tạo ra những biến động giá phức tạp trong ngắn và trung hạn. Chuỗi giá cổ phiếu JFC không chỉ thể hiện các xu hướng tăng trưởng mang tính tuyến tính, mà còn xuất hiện những dao động bất thường và các cú sốc phi tuyến, thể hiện qua sự hình thành của các mô hình kỹ thuật như “hai đỉnh” hoặc các đợt sụt giảm mạnh được ghi nhận vào cuối năm 2025. Những đặc điểm này phản ánh mức độ nhạy cảm của cổ phiếu đối với cả thông tin doanh nghiệp và các biến động vĩ mô, đồng thời làm gia tăng độ khó trong công tác dự báo.

Trong bối cảnh đó, việc nghiên cứu và dự báo giá cổ phiếu JFC không chỉ mang ý nghĩa thực tiễn đối với các nhà đầu tư quan tâm đến thị trường chứng khoán Philippines, mà còn đóng vai trò như một trường hợp kiểm thử (benchmark) phù hợp để đánh giá hiệu quả của các mô hình dự báo giá cổ phiếu trong điều kiện thị trường có mức độ biến động cao. Thông qua trường hợp JFC, nghiên cứu có thể cung cấp thêm bằng chứng thực nghiệm về khả năng ứng dụng của các phương pháp dự báo tiên tiến trong việc xử lý chuỗi thời gian tài chính phức tạp tại các thị trường mới nổi.

1.1.3. Khoảng trống phương pháp luận

Trong nhiều thập kỷ, mô hình ARIMA (AutoRegressive Integrated Moving Average) do Box và Jenkins (1970) đề xuất đã được sử dụng rộng rãi trong dự báo chuỗi thời gian đơn biến. Nhờ nền tảng lý thuyết chặt chẽ và cấu trúc rõ ràng, ARIMA đặc biệt hiệu quả trong việc mô hình hóa các mối quan hệ tuyến tính và xu hướng dài hạn của dữ liệu. Chính vì vậy, mô hình này thường được xem là điểm xuất phát chuẩn trong các nghiên cứu dự báo chuỗi thời gian truyền thống. Tuy nhiên, ARIMA cũng tồn tại những hạn chế nhất định, xuất phát từ các giả định về tính tuyến tính và phương sai không đổi của chuỗi dữ liệu. Khi áp dụng cho dữ liệu tài chính – vốn thường có đặc điểm nhiễu cao, biến động mạnh và chịu ảnh hưởng của các yếu tố phi tuyến – mô hình ARIMA gặp khó khăn trong việc nhận diện các điểm đảo chiều hay các cú sốc giá, từ đó làm gia tăng sai số dự báo (Zhang, 2003).

Song song với đó, sự phát triển nhanh chóng của các phương pháp Học máy (Machine Learning) đã mở ra những hướng tiếp cận mới trong dự báo chuỗi thời gian tài chính. Một trong những thuật toán tiêu biểu là XGBoost (Extreme Gradient Boosting), được giới thiệu bởi Chen và Guestrin (2016). XGBoost thuộc nhóm các mô hình học tổ hợp (Ensemble Learning), nổi bật với khả năng học các mối quan hệ phi tuyến phức tạp và tự động nắm bắt các tương tác giữa biến số mà không yêu cầu giả định chặt chẽ về phân phối dữ liệu. Nhờ những đặc điểm này, XGBoost đã được ứng dụng rộng rãi trong nhiều bài toán dự báo và phân loại trong lĩnh vực tài chính. Tuy nhiên, khi được áp dụng trực tiếp lên chuỗi thời gian thô, mô hình này có thể gặp hạn chế trong việc ngoại suy xu hướng dài hạn và dễ rơi vào tình trạng quá khớp, đặc biệt trong bối cảnh dữ liệu tài chính có mức độ nhiễu cao.

Từ những ưu điểm và hạn chế nêu trên, một vấn đề nghiên cứu quan trọng được đặt ra là làm thế nào để kết hợp hiệu quả khả năng mô hình hóa xu hướng tuyến tính của ARIMA với năng lực xử lý các cấu trúc phi tuyến của XGBoost trong cùng một khung phân tích. Để giải quyết câu hỏi này, nghiên cứu đề xuất cách tiếp cận mô hình lai (hybrid

model) dựa trên nguyên lý hiệu chỉnh phần dư (residual correction). Theo đó, chuỗi thời gian tài chính được giả định gồm hai thành phần chính: một thành phần tuyến tính và một thành phần phi tuyến. ARIMA được sử dụng để ước lượng và loại bỏ thành phần tuyến tính của chuỗi, trong khi phần dư còn lại được xem là đại diện cho các động lực phi tuyến, vốn có thể được khai thác hiệu quả bởi XGBoost.

Cách tiếp cận này đã và đang nhận được sự quan tâm trong các nghiên cứu gần đây, cho thấy tiềm năng cải thiện đáng kể độ chính xác dự báo so với việc sử dụng các mô hình đơn lẻ. Các nghiên cứu của Pan (2023) và Wang et al. (2024) cung cấp bằng chứng thực nghiệm cho thấy mô hình lai ARIMA–XGBoost có khả năng nắm bắt tốt hơn cả xu hướng dài hạn lẫn các biến động ngắn hạn trong dữ liệu tài chính. Trong bối cảnh nghiên cứu này, phương pháp trên được kỳ vọng sẽ mang lại kết quả dự báo hiệu quả hơn đối với giá cổ phiếu Jollibee, đồng thời đóng góp thêm bằng chứng thực nghiệm cho hướng tiếp cận mô hình lai trong các thị trường mới nổi.

1.2. MỤC TIÊU NGHIÊN CỨU

Nghiên cứu này không chỉ dừng lại ở việc áp dụng công thức, mà hướng tới việc xây dựng một quy trình (framework) dự báo hoàn chỉnh, khoa học và có thể tái lập. Các mục tiêu được chia làm hai cấp độ:

1.2.1. Mục tiêu tổng quát

Xây dựng, tối ưu hóa và kiểm định hiệu quả của mô hình lai ghép **ARIMA-XGBoost** trong việc dự báo giá đóng cửa của cổ phiếu Jollibee Foods Corp (JBFCF), nhằm cung cấp một công cụ hỗ trợ ra quyết định đầu tư định lượng (Quantitative Trading) với độ tin cậy cao.

1.2.2. Mục tiêu cụ thể

Để đạt được mục tiêu tổng quát, nghiên cứu sẽ thực hiện các nhiệm vụ cụ thể sau:

1. **Phân tích đặc điểm chuỗi dữ liệu:** Kiểm định các thuộc tính thống kê của chuỗi giá cổ phiếu JFC (tính dừng, tự tương quan, tính mùa vụ) giai đoạn 2024-2025 để làm cơ sở chọn lựa tham số mô hình.
2. **Mô hình hóa thành phần tuyến tính (Linear Modeling):** Xây dựng mô hình ARIMA tối ưu thông qua quy trình Box-Jenkins để nắm bắt xu hướng chủ đạo và trích xuất phần sai số (residuals).
3. **Mô hình hóa thành phần phi tuyến (Non-linear Modeling):** Thiết kế và huấn luyện thuật toán XGBoost để dự báo phần sai số của ARIMA, thông qua việc kỹ thuật đặc trưng (Feature Engineering) từ các độ trễ và biến động quá khứ.
4. **Đánh giá và So sánh:** Định lượng mức độ cải thiện hiệu suất dự báo của mô hình Lai so với mô hình ARIMA đơn lẻ thông qua các chỉ số RMSE, MAE, MAPE và kiểm chứng sự phù hợp của mô hình trong giai đoạn biến động mạnh (Downtrend/Flash Crash).
5. **Ứng dụng thực tiễn:** Cung cấp các dự báo giá ngắn hạn (10-30 ngày) và đưa ra các khuyến nghị giao dịch dựa trên kết quả mô hình.

1.3. CÂU HỎI NGHIÊN CỨU

Nghiên cứu được thiết kế để trả lời ba câu hỏi cốt lõi sau đây, tương ứng với dòng chảy logic của bài toán:

- **Câu hỏi 1:** Mô hình ARIMA có đủ khả năng giải thích biến động giá cổ phiếu Jollibee giai đoạn 2024-2025 hay không?
- **Câu hỏi 2:** Việc áp dụng thuật toán XGBoost lên phần dư (residuals) của ARIMA có thực sự phát hiện được các mẫu hình phi tuyến ẩn giấu hay không? Cụ thể, mô hình lai giúp giảm bao nhiêu phần trăm sai số (RMSE) so với mô hình đơn lẻ?

1.4. ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU

1.4.1. Đối tượng nghiên cứu

- **Đối tượng vật lý:** Cổ phiếu của Jollibee Foods Corporation.
- **Đối tượng số liệu:** Chuỗi thời gian giá đóng cửa (Close Price). Giá đóng cửa được chọn vì đây là mức giá quan trọng nhất, phản ánh sự đồng thuận cuối cùng của thị trường sau một ngày giao dịch và được sử dụng làm chuẩn cho các định giá tài sản.

1.4.2. Phạm vi dữ liệu

- **Nguồn dữ liệu:** Dữ liệu thứ cấp được trích xuất từ **Yahoo Finance** (thư viện yfinance), đảm bảo tính chính xác và cập nhật theo thời gian thực.
- **Mã chứng khoán:** JBFCF (Giao dịch trên thị trường OTC, phản ánh diễn biến toàn cầu của Jollibee).
- **Khung thời gian:** Từ ngày **01/01/2024** đến ngày **18/12/2025**.

Đây là khung thời gian đủ dài (gần 2 năm, bao gồm 494-513 điểm dữ liệu) để huấn luyện mô hình học máy, nhưng cũng đủ ngắn để đảm bảo tính cập nhật. Quan trọng hơn, giai đoạn này bao gồm đầy đủ các pha của thị trường: Tích lũy (Sideways đầu 2024), Tăng trưởng giả (Bull trap), và Suy thoái (Downtrend cuối 2025), tạo điều kiện lý tưởng để kiểm thử độ bền vững (robustness) của mô hình (Jollibee Foods Corporation, 2024; Simply Wall St, 2025).

1.4.3. Phạm vi nội dung

Nghiên cứu tập trung sâu vào **phân tích kỹ thuật định lượng (Quantitative Technical Analysis)**. Các yếu tố phân tích cơ bản (Doanh thu, Lợi nhuận, P/E) hoặc phân tích tin tức (Sentiment Analysis) không nằm trong phạm vi mô hình hóa trực tiếp của bài báo này, mặc dù có thể được thảo luận trong phần bối cảnh.

1.5. Ý nghĩa khoa học và thực tiễn

1.5.1. Ý nghĩa khoa học

Nghiên cứu này đóng góp vào việc mở rộng cơ sở lý luận về dự báo chuỗi thời gian tài chính, đặc biệt trong bối cảnh các thị trường đang phát triển với đặc điểm biến động cao và dữ liệu phức tạp. Thông qua việc kết hợp các mô hình kinh tế lượng truyền thống với phương pháp học máy hiện đại, nghiên cứu làm rõ tính khả thi và hiệu quả của cách tiếp cận theo hướng phân rã và tổng hợp (decomposition–ensemble) trong phân tích dữ liệu tài chính quy mô lớn.

Bên cạnh đó, kết quả thực nghiệm của nghiên cứu cho thấy phần dư thu được từ các mô hình tuyến tính không hoàn toàn là nhiễu trắng ngẫu nhiên như một số giả định cổ điển. Thay vào đó, các phần dư này có thể chứa đựng những cấu trúc phi tuyến và thông tin hữu ích, có thể được khai thác thông qua các mô hình học máy phù hợp. Phát hiện này góp phần bổ sung bằng chứng thực nghiệm cho hướng nghiên cứu kết hợp mô hình tuyến tính và phi tuyến trong dự báo chuỗi thời gian tài chính.

1.5.2. Ý nghĩa thực tiễn

Về mặt ứng dụng, nghiên cứu mang lại một số giá trị thực tiễn đối với các nhóm đối tượng khác nhau trên thị trường tài chính. Đối với nhà đầu tư cá nhân, kết quả dự báo có thể được sử dụng như một nguồn tham khảo mang tính khách quan, hỗ trợ việc nhận diện các vùng giá mua và bán hợp lý, đồng thời góp phần hạn chế các quyết định mang tính cảm xúc như chạy theo tâm lý đám đông hoặc bán tháo trong giai đoạn thị trường biến động mạnh.

Đối với các nhà quản lý quỹ và tổ chức đầu tư, nghiên cứu đề xuất một khung mô hình linh hoạt, có khả năng mở rộng và điều chỉnh để áp dụng cho nhiều loại tài sản và danh mục đầu tư khác nhau. Cách tiếp cận này có thể hỗ trợ quá trình ra quyết định đầu tư, đặc biệt trong môi trường thị trường có mức độ bất định cao.

Ngoài ra, đối với giới học thuật và sinh viên, nghiên cứu cung cấp một quy trình phân tích tương đối hoàn chỉnh cùng với mã nguồn minh họa bằng Python, có thể được

sử dụng như tài liệu tham khảo trong học tập và nghiên cứu về dự báo chuỗi thời gian, tài chính định lượng và kỹ thuật tài chính (Financial Engineering).

1.6. CẤU TRÚC BÁO CÁO

Báo cáo được cấu trúc thành 5 chương chính, tuân thủ logic diễn giải từ lý thuyết đến thực nghiệm:

- **Chương 1: Giới thiệu (Introduction):** (Phần đang trình bày) Đặt vấn đề, mục tiêu và phạm vi nghiên cứu.
- **Chương 2: Cơ sở lý luận (Literature Review):** Hệ thống hóa các lý thuyết về dự báo chứng khoán, đi sâu vào cấu trúc toán học của ARIMA, thuật toán XGBoost và cơ chế hoạt động của Mô hình Lai.
- **Chương 3: Phương pháp nghiên cứu (Methodology):** Mô tả chi tiết quy trình thu thập, xử lý dữ liệu, thiết kế thuật toán và các tiêu chí đánh giá hiệu quả (Metrics).
- **Chương 4: Kết quả thực nghiệm và Thảo luận (Empirical Results):** Trình bày các biểu đồ phân tích, kết quả chạy mô hình, so sánh sai số và đưa ra các dự báo tương lai.
- **Chương 5: Kết luận (Conclusion):** Tổng kết các phát hiện chính, hạn chế của nghiên cứu và gợi ý hướng phát triển tiếp theo.

PHẦN 2. CƠ SỞ LÝ LUẬN VÀ TỔNG QUAN NGHIÊN CỨU (LITERATURE REVIEW)

2.1. LÝ THUYẾT NỀN TẢNG VỀ DỰ BÁO CHUỖI THỜI GIAN TÀI CHÍNH

2.1.1. Khái niệm và Đặc trưng của Chuỗi thời gian Tài chính

Chuỗi thời gian tài chính (financial time series) là tập hợp các quan sát về giá trị của các tài sản tài chính, chẳng hạn như giá cổ phiếu, chỉ số thị trường hay tỷ giá hối đoái, được ghi nhận theo trình tự thời gian với các khoảng cách quan sát tương đối đều nhau như ngày, tuần hoặc tháng. Loại dữ liệu này đóng vai trò nền tảng trong nhiều nghiên cứu về phân tích và dự báo thị trường tài chính.

So với các chuỗi thời gian trong lĩnh vực vật lý hoặc kỹ thuật, chuỗi thời gian tài chính có những đặc điểm thống kê phức tạp hơn, đặc biệt khi xét đến dữ liệu giá cổ phiếu như Jollibee (JBFCF) (Wang & Guo, 2020). Trước hết, chuỗi giá thường không dừng, thể hiện ở việc kỳ vọng và phương sai của dữ liệu thay đổi theo thời gian. Đặc điểm này phản ánh sự tác động liên tục của các yếu tố kinh tế vĩ mô, thông tin doanh nghiệp và kỳ vọng của nhà đầu tư, khiến cho các giả định về tính ổn định trong dài hạn khó được thỏa mãn.

Bên cạnh đó, chuỗi thời gian tài chính thường xuất hiện hiện tượng phương sai thay đổi theo thời gian, hay còn gọi là biến động phương sai (heteroskedasticity). Mức độ biến động của giá không phân bố đồng đều mà có xu hướng tập trung thành từng cụm, trong đó các giai đoạn biến động mạnh thường nối tiếp nhau, xen kẽ với những giai đoạn tương đối ổn định. Hiện tượng này, thường được gọi là “volatility clustering”, là một trong những thách thức lớn đối với các mô hình dự báo truyền thống.

Ngoài ra, dữ liệu giá cổ phiếu còn chịu ảnh hưởng đáng kể từ các yếu tố ngẫu nhiên như tin tức bất ngờ, sự kiện thị trường và tâm lý hành vi của nhà đầu tư. Điều này làm cho tỷ lệ tín hiệu trên nhiễu trong chuỗi dữ liệu tương đối thấp, gây khó khăn trong việc tách biệt các quy luật tiềm ẩn khỏi các dao động ngẫu nhiên. Chính những đặc trưng này

khuyến cho việc mô hình hóa và dự báo chuỗi thời gian tài chính đòi hỏi các phương pháp phân tích linh hoạt và phù hợp hơn so với các lĩnh vực dữ liệu khác.

2.1.2. Tính dừng (Stationarity) và Kiểm định Nghiệm đơn vị

Tính dừng là một giả định thống kê quan trọng và mang tính tiên quyết đối với các mô hình chuỗi thời gian tuyến tính, điển hình như ARIMA. Một chuỗi thời gian Y_t được gọi là dừng yếu (weakly stationary) khi thỏa mãn ba điều kiện cơ bản (Hyndman & Athanasopoulos, 2018). Thứ nhất, kỳ vọng của chuỗi phải không đổi theo thời gian, tức là $E(Y_t) = \mu$ với mọi t . Thứ hai, phương sai của chuỗi cũng phải là hằng số, được biểu diễn bởi $Var(Y_t) = \sigma^2$ với mọi thời điểm quan sát. Cuối cùng, hiệp phương sai giữa hai quan sát trong chuỗi chỉ phụ thuộc vào độ trễ k , mà không phụ thuộc vào thời điểm cụ thể t , hay $Cov(Y_t, Y_{t-k}) = \gamma_k$.

Trong thực tế, hầu hết các chuỗi giá chứng khoán gốc (Pt) không thỏa mãn các điều kiện trên, do thường chứa xu hướng ngẫu nhiên và chịu tác động của nhiều yếu tố kinh tế – tài chính biến động theo thời gian. Vì vậy, các chuỗi này thường được xem là không dừng. Để có thể áp dụng các mô hình tuyến tính như ARIMA, dữ liệu cần được chuyển đổi về dạng dừng thông qua các kỹ thuật tiền xử lý, trong đó sai phân (differencing) là phương pháp phổ biến nhất. Sai phân bậc nhất được xác định theo công thức:

$$\Delta Y_t = Y_t - Y_{t-1}$$

Phép biến đổi này giúp loại bỏ xu hướng và làm ổn định kỳ vọng của chuỗi theo thời gian.

Việc kiểm tra tính dừng của chuỗi thời gian thường được thực hiện bằng Kiểm định Augmented Dickey–Fuller (ADF). Kiểm định này nhằm đánh giá sự tồn tại của nghiệm đơn vị trong chuỗi dữ liệu. Nếu giá trị thống kê ADF nhỏ hơn giá trị tới hạn tương ứng, giả thuyết không H_0 (chuỗi có nghiệm đơn vị và không dừng) sẽ bị bác bỏ, từ đó cho

phép kết luận rằng chuỗi thời gian là dừng ở mức ý nghĩa thống kê đã chọn (Rehal, 2023).

2.1.3. Giả thuyết Bước đi ngẫu nhiên (Random Walk Hypothesis)

Lý thuyết Bước đi ngẫu nhiên (Random Walk Theory), gắn liền với Giả thuyết Thị trường Hiệu quả (Efficient Market Hypothesis – EMH) do Fama (1970) đề xuất, cho rằng biến động giá cổ phiếu diễn ra một cách độc lập và về cơ bản không thể dự báo. Theo cách tiếp cận này, giá cổ phiếu tại thời điểm t được mô tả như sau:

$$P_t = P_{t-1} + \epsilon_t$$

trong đó ϵ_t là nhiễu trắng (white noise), đại diện cho các cú sốc ngẫu nhiên và không có cấu trúc dự đoán.

Dưới giả định bước đi ngẫu nhiên, mọi thông tin sẵn có đã được phản ánh đầy đủ vào giá, khiến cho các biến động trong tương lai không phụ thuộc vào quá khứ. Điều này hàm ý rằng việc xây dựng các mô hình dự báo dựa trên dữ liệu lịch sử sẽ không mang lại lợi thế đáng kể so với các chiến lược đầu tư thụ động. Tuy nhiên, trong những thập kỷ gần đây, nhiều nghiên cứu thực nghiệm đã chỉ ra rằng thị trường tài chính trong thực tế không hoàn toàn tuân theo giả định này.

Cụ thể, các bằng chứng cho thấy sự tồn tại của hiện tượng trí nhớ dài hạn (long memory), cũng như các mẫu hình phi tuyến phát sinh từ hành vi bầy đàn của nhà đầu tư, sự phản ứng không đồng đều trước thông tin mới và tình trạng bất cân xứng thông tin trên thị trường. Những đặc điểm này khiến cho chuỗi giá cổ phiếu có thể xuất hiện các cấu trúc phụ thuộc theo thời gian, tạo ra những sai lệch nhất định so với mô hình bước đi ngẫu nhiên thuần túy.

Chính những sai lệch này mở ra cơ hội cho việc ứng dụng các mô hình dự báo tiên tiến, đặc biệt là các phương pháp học máy có khả năng nắm bắt quan hệ phi tuyến và tương tác phức tạp trong dữ liệu. Các nghiên cứu gần đây, chẳng hạn như Meher và cộng

sự (2024), cho thấy các mô hình như XGBoost có thể khai thác hiệu quả những cấu trúc tiềm ẩn này, từ đó cải thiện độ chính xác dự báo trong bối cảnh thị trường không hoàn toàn hiệu quả.

2.2. MÔ HÌNH ARIMA (AUTOREGRESSIVE INTEGRATED MOVING AVERAGE)

2.2.1. Cấu trúc mô hình

Mô hình ARIMA (AutoRegressive Integrated Moving Average), được đề xuất bởi Box và Jenkins (1970), là một trong những mô hình kinh điển trong phân tích và dự báo chuỗi thời gian, với mục tiêu mô hình hóa các mối quan hệ tuyến tính tồn tại trong dữ liệu. ARIMA được ký hiệu dưới dạng ARIMA(p,d,q), trong đó mỗi tham số đại diện cho một thành phần cấu trúc riêng biệt của mô hình.

Thành phần tự hồi quy AR(p) mô tả mối quan hệ giữa giá trị hiện tại của chuỗi và p giá trị trễ của chính nó. Cụ thể, mô hình AR(p) có dạng:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \epsilon_t$$

trong đó c là hằng số, ϕ_i là các hệ số tự hồi quy và ϵ_t là sai số ngẫu nhiên.

Thành phần tích hợp I(d) phản ánh số bậc sai phân cần thiết để đưa chuỗi thời gian ban đầu về trạng thái dừng. Trong các ứng dụng tài chính, dữ liệu giá thường không dừng và phổ biến nhất là sử dụng sai phân bậc nhất (d=1) nhằm loại bỏ xu hướng và làm ổn định kỳ vọng của chuỗi.

Thành phần trung bình trượt MA(q) mô hình hóa mối quan hệ giữa giá trị hiện tại của chuỗi và q sai số dự báo trong quá khứ. Dạng tổng quát của mô hình MA(q) được biểu diễn như sau:

$$Y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \dots + \theta_q \epsilon_{t-q}$$

trong đó μ là kỳ vọng của chuỗi và θ_j là các hệ số trung bình trượt.

Kết hợp ba thành phần trên, mô hình ARIMA có thể được biểu diễn dưới dạng toán tử trễ (lag operator) như sau:

$$(1 - \sum_{i=1}^p \phi_i L^i)(1 - L)^d Y_t = (1 + \sum_{j=1}^q \phi_j L^j) \epsilon_t$$

trong đó L là toán tử trễ, với $L^k Y_t = Y_{t-k}$.

Cách biểu diễn này cho thấy ARIMA là một khung mô hình linh hoạt, cho phép kết hợp đồng thời động lực quá khứ của chuỗi, tác động của các cú sốc ngẫu nhiên và quá trình biến đổi dữ liệu để đảm bảo tính dừng, từ đó tạo nền tảng cho nhiều ứng dụng dự báo chuỗi thời gian trong tài chính.

2.2.2. Quy trình Box-Jenkins

1. Quy trình xây dựng và hiệu chỉnh mô hình ARIMA thường được thực hiện theo ba bước cơ bản. Ở bước thứ nhất, giai đoạn nhận dạng mô hình (identification), các đặc trưng thống kê của chuỗi thời gian được phân tích nhằm xác định cấu trúc phù hợp của mô hình. Cụ thể, các đồ thị tự tương quan (Autocorrelation Function – ACF) và tự tương quan riêng phần (Partial Autocorrelation Function – PACF) được sử dụng để ước lượng các tham số p và q , trong khi bậc sai phân d được xác định dựa trên kết quả kiểm tra tính dừng của chuỗi.
2. Bước tiếp theo là giai đoạn ước lượng tham số (estimation). Tại đây, các hệ số của thành phần tự hồi quy và trung bình trượt, tương ứng với ϕ và θ , được ước lượng bằng các phương pháp thống kê phù hợp. Hai phương pháp được sử dụng phổ biến là phương pháp bình phương tối thiểu và phương pháp cực đại hóa hàm hợp lý, trong đó phương pháp cực đại hóa hàm hợp lý thường được ưu tiên nhờ tính hiệu quả trong bối cảnh dữ liệu tài chính.

3. Cuối cùng, giai đoạn kiểm định mô hình (diagnostic checking) được thực hiện nhằm đánh giá mức độ phù hợp của mô hình đã ước lượng. Phần dư của mô hình được phân tích để kiểm tra xem chúng có còn tồn tại tự tương quan hay không. Một mô hình ARIMA được xem là phù hợp khi phần dư thể hiện đặc tính của nhiễu trắng, tức là không còn chứa thông tin có cấu trúc chưa được mô hình hóa.

2.2.3. Ưu điểm và Hạn chế

- Về mặt ưu điểm, ARIMA sở hữu nền tảng lý thuyết thống kê vững chắc và đã được kiểm chứng rộng rãi trong nhiều nghiên cứu thực nghiệm. Mô hình này đặc biệt hiệu quả trong việc mô hình hóa các xu hướng tuyến tính và động lực ngắn hạn của chuỗi thời gian, qua đó thường mang lại kết quả dự báo ổn định trong những bối cảnh dữ liệu có cấu trúc tương đối đơn giản (Wang & Guo, 2020).
- Tuy nhiên, hạn chế lớn nhất của ARIMA xuất phát từ giả định quan hệ tuyến tính giữa các quan sát trong chuỗi. Trong môi trường thị trường chứng khoán, nơi dữ liệu thường có mức độ biến động cao và chịu ảnh hưởng của nhiều yếu tố phi tuyến, mô hình ARIMA gặp khó khăn trong việc nắm bắt các biến động bất thường cũng như các mẫu hình phức tạp. Hệ quả là phần sai số của mô hình thường không đơn thuần là nhiễu ngẫu nhiên mà có thể chứa đựng những thông tin phi tuyến chưa được khai thác, làm giảm độ chính xác dự báo, đặc biệt trong các giai đoạn thị trường biến động mạnh (Zhao và cộng sự, 2025).

2.3. MÔ HÌNH XGBOOST (EXTREME GRADIENT BOOSTING)

2.3.1. Giới thiệu thuật toán

XGBoost là một thuật toán học máy thuộc nhóm học kết hợp (Ensemble Learning), cụ thể là phương pháp Gradient Boosting trên cây quyết định (Gradient Boosting Decision Trees – GBDT), được Chen và Guestrin giới thiệu vào năm 2016. Thuật toán này được thiết kế nhằm khắc phục những hạn chế về hiệu năng và khả năng mở rộng của các mô hình boosting truyền thống.

Khác với các mô hình cây quyết định đơn lẻ, XGBoost xây dựng một tập hợp các cây quyết định theo trình tự tuần tự. Trong quá trình huấn luyện, mỗi cây mới được tạo ra với mục tiêu hiệu chỉnh phần sai số (residuals) còn tồn tại từ các cây trước đó. Thông qua cơ chế này, mô hình dần cải thiện khả năng dự báo bằng cách tập trung vào những quan sát mà các bước trước chưa mô hình hóa tốt, từ đó nâng cao độ chính xác tổng thể.

2.3.2. Cơ chế hoạt động và Hàm mục tiêu

Mục tiêu của thuật toán XGBoost là tối thiểu hóa một hàm mục tiêu (objective function) bao gồm hai thành phần chính: hàm mất mát đo lường sai số dự báo và thành phần điều chuẩn nhằm kiểm soát độ phức tạp của mô hình. Hàm mục tiêu tổng quát của XGBoost được biểu diễn như sau:

$$L(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k)$$

trong đó $l(\hat{y}_i, y_i)$ là hàm mất mát, thường được lựa chọn dưới dạng sai số bình phương trung bình (Mean Squared Error – MSE) đối với các bài toán hồi quy, nhằm đánh giá mức độ sai lệch giữa giá trị dự báo $\hat{y}_i$ và giá trị thực tế y_i .

Thành phần $\Omega(f_k)$ đóng vai trò điều chuẩn, được sử dụng để kiểm soát độ phức tạp của từng cây quyết định f_k trong mô hình. Cụ thể, hàm điều chuẩn thường được xác định như sau:

$$\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \|w\|^2$$

trong đó T là số lượng lá của cây, w là vector trọng số của các lá, còn γ và λ là các tham số điều chỉnh mức độ phạt. Thành phần này giúp hạn chế việc mô hình trở nên quá phức tạp, từ đó giảm nguy cơ quá khớp (overfitting), đặc biệt khi làm việc với dữ liệu tài chính có mức độ nhiễu cao.

Để tối ưu hóa hàm mục tiêu, XGBoost sử dụng khai triển Taylor bậc hai của hàm mất mát, cho phép khai thác đồng thời thông tin về gradient bậc nhất và bậc hai. Cách tiếp cận này giúp quá trình tối ưu hội tụ nhanh hơn và ổn định hơn so với các phương pháp Gradient Boosting truyền thống, đồng thời nâng cao hiệu quả dự báo trong các bài toán phức tạp (Chen & Guestrin, 2016).

2.3.3. Lý do lựa chọn XGBoost cho dữ liệu tài chính

XGBoost thể hiện ưu thế rõ rệt trong việc xử lý các mối quan hệ phi tuyến phức tạp, cho phép mô hình hóa những cấu trúc dữ liệu đứt gãy và không tuyến tính mà không cần đặt ra các giả định chặt chẽ về phân phối xác suất của dữ liệu đầu vào. Đặc điểm này đặc biệt phù hợp với dữ liệu thị trường chứng khoán, nơi hành vi giá thường chịu tác động đồng thời của nhiều yếu tố khó dự đoán.

Bên cạnh đó, thuật toán được trang bị cơ chế điều chuẩn tích hợp, bao gồm các dạng phạt L1 và L2, giúp kiểm soát độ phức tạp của mô hình và nâng cao khả năng chịu nhiễu. Nhờ vậy, XGBoost có thể duy trì hiệu quả dự báo ngay cả khi dữ liệu chứa nhiều biến động ngẫu nhiên và nhiễu cao – một đặc trưng phổ biến của chuỗi thời gian tài chính (Wang và cộng sự, 2024).

Ngoài hiệu quả về mặt mô hình hóa, XGBoost còn nổi bật về tốc độ tính toán. Thuật toán hỗ trợ tối ưu hóa song song và khai thác hiệu quả tài nguyên phần cứng, cho phép rút ngắn đáng kể thời gian huấn luyện. Điều này tạo điều kiện thuận lợi cho việc huấn luyện lại mô hình một cách thường xuyên, đáp ứng yêu cầu cập nhật liên tục trong các ứng dụng dự báo và giao dịch thực tế.

2.4. MÔ HÌNH LAI (HYBRID MODEL) VÀ LÝ THUYẾT PHÂN RÃ SAI SỐ

2.4.1. Cơ sở lý thuyết của Phương pháp Lai ghép

Ý tưởng cốt lõi của mô hình lai ARIMA–XGBoost bắt nguồn từ nhận định kinh điển của Zhang (2003) rằng *“không một mô hình đơn lẻ nào có thể nắm bắt đầy đủ mọi*

đặc điểm của một chuỗi thời gian phức tạp”. Đặc biệt trong bối cảnh thị trường tài chính, chuỗi giá cổ phiếu thường đồng thời chứa đựng cả cấu trúc tuyến tính ổn định và các biến động phi tuyến khó lường, xuất phát từ tâm lý nhà đầu tư, cú sốc thông tin và các yếu tố hành vi.

Theo cách tiếp cận này, một chuỗi thời gian tài chính Y_t có thể được biểu diễn như sự tổng hợp của ba thành phần chính:

$$Y_t = L_t + N_t + \epsilon_t$$

trong đó L_t đại diện cho thành phần tuyến tính (linear component), phản ánh các xu hướng, chu kỳ và mối quan hệ phụ thuộc theo thời gian; N_t là thành phần phi tuyến (non-linear component), bao gồm các mẫu hình phức tạp, đứt gãy cấu trúc và hiệu ứng hành vi; còn ϵ_t là nhiễu ngẫu nhiên không thể dự báo.

Dựa trên sự phân rã này, mô hình lai ARIMA–XGBoost được thiết kế theo kiến trúc hai giai đoạn (two-stage architecture), nhằm tận dụng thế mạnh bổ sung lẫn nhau của mô hình thống kê truyền thống và thuật toán học máy hiện đại.

Ở **giai đoạn thứ nhất**, mô hình ARIMA được sử dụng để mô hình hóa thành phần tuyến tính L_t . Nhờ nền tảng lý thuyết thống kê vững chắc, ARIMA có khả năng nắm bắt tốt các cấu trúc tự tương quan và xu hướng ngắn hạn trong chuỗi thời gian. Kết quả của bước này là giá trị dự báo tuyến tính $\hat{L}_t$

Tiếp theo, ở **giai đoạn thứ hai**, phần dư được tính toán theo công thức:

$$e_t = Y_t - \hat{L}_t$$

Về mặt lý thuyết, nếu ARIMA đã mô hình hóa hiệu quả phần tuyến tính, thì phần dư e_t sẽ chứa đựng chủ yếu các thông tin phi tuyến N_t mà mô hình tuyến tính không thể nắm bắt. Đây chính là “không gian cơ hội” để các thuật toán học máy phát huy ưu thế.

Trong bước này, XGBoost được áp dụng để học và dự báo cấu trúc phi tuyến ẩn trong chuỗi phần dư et, từ đó tạo ra dự báo $\hat{N}_t$. Nhờ khả năng mô hình hóa các quan hệ phức tạp, không tuyến tính và chịu nhiễu tốt, XGBoost đóng vai trò bổ sung hoàn hảo cho ARIMA trong mô hình lai.

Cuối cùng, **dự báo tổng hợp** của mô hình ARIMA–XGBoost được xác định bằng cách cộng hai thành phần dự báo:

$$\hat{Y}_{final} = \hat{L}_t + \hat{N}_t$$

Cách tiếp cận này cho phép mô hình tận dụng đồng thời tính diễn giải và ổn định của ARIMA cùng với sức mạnh học phi tuyến của XGBoost, từ đó cải thiện đáng kể độ chính xác dự báo trong môi trường thị trường tài chính nhiều biến động.

2.4.2. Tổng quan các nghiên cứu thực nghiệm

Nhiều nghiên cứu trước đây đã cung cấp bằng chứng thực nghiệm mạnh mẽ cho thấy tính hiệu quả và tính tổng quát của các mô hình lai, đặc biệt là các mô hình kết hợp giữa phương pháp thống kê truyền thống và thuật toán học máy hiện đại.

Zhang (2003) được xem là công trình nền tảng đặt viên gạch đầu tiên cho hướng tiếp cận này. Trong nghiên cứu của mình, tác giả đề xuất mô hình lai kết hợp ARIMA và Mạng nơ-ron nhân tạo (Artificial Neural Networks – ANN), dựa trên giả định rằng ARIMA phù hợp để mô hình hóa cấu trúc tuyến tính, trong khi ANN có khả năng học các quan hệ phi tuyến phức tạp còn sót lại trong phần dư. Kết quả thực nghiệm cho thấy mô hình lai luôn cho hiệu quả dự báo tốt hơn hoặc ít nhất là tương đương với mô hình đơn lẻ tốt nhất trong từng bối cảnh, qua đó khẳng định tính ưu việt của cách tiếp cận phân rã chuỗi thời gian thành các thành phần tuyến tính và phi tuyến.

Tiếp nối hướng nghiên cứu này, Pai và Lin (2005) mở rộng mô hình lai bằng cách kết hợp ARIMA với Support Vector Machines (SVM) trong bài toán dự báo giá cổ phiếu. Nghiên cứu chỉ ra rằng việc sử dụng SVM để mô hình hóa phần dư của ARIMA giúp

giảm thiểu đáng kể rủi ro lựa chọn sai mô hình (model misspecification), đồng thời cải thiện độ ổn định của kết quả dự báo trong môi trường thị trường tài chính nhiều nhiễu và biến động mạnh.

Trong những năm gần đây, cùng với sự phát triển của các thuật toán Boosting, nhiều nghiên cứu đã tập trung vào việc kết hợp ARIMA với XGBoost – một trong những thuật toán học máy mạnh mẽ và hiệu quả nhất hiện nay. Wang et al. (2024) và Pan (2023) đã áp dụng thành công mô hình lai ARIMA–XGBoost cho các thị trường tài chính khác nhau, bao gồm thị trường chứng khoán truyền thống và thị trường tiền tệ kỹ thuật số. Kết quả cho thấy mô hình lai này giúp giảm đáng kể các chỉ tiêu sai số như RMSE và MAPE so với cả các mô hình thống kê đơn lẻ lẫn các mô hình Deep Learning phức tạp như LSTM, đặc biệt trong trường hợp tập dữ liệu có kích thước trung bình – một kịch bản phổ biến trong thực tế nghiên cứu tài chính.

Đáng chú ý, Meher et al. (2024) nhấn mạnh vai trò của các thuật toán Boosting trong việc xử lý phần dư của ARIMA. Nghiên cứu chỉ ra rằng XGBoost và các biến thể Boosting khác có khả năng nắm bắt tốt hơn các cú sốc biến động (volatility shocks) và các biến động bất thường trong thị trường, vốn thường bị bỏ sót bởi các mô hình tuyến tính và ngay cả một số mô hình học sâu khi dữ liệu không đủ lớn.

Tổng hợp các kết quả từ những nghiên cứu trên cho thấy mô hình lai ARIMA–XGBoost không chỉ có cơ sở lý thuyết vững chắc mà còn được kiểm chứng rộng rãi về mặt thực nghiệm. Cách tiếp cận này đặc biệt phù hợp trong bối cảnh dữ liệu tài chính có kích thước vừa phải, nhiễu nhiều và chứa đựng đồng thời cả cấu trúc tuyến tính lẫn phi tuyến, qua đó tạo tiền đề vững chắc cho việc áp dụng trong nghiên cứu này.

2.4.3. Khoảng trống nghiên cứu (Research Gap)

Mặc dù các mô hình lai kết hợp giữa phương pháp thống kê và học máy đã được nghiên cứu và chứng minh hiệu quả trong nhiều bối cảnh thị trường khác nhau, việc ứng dụng cụ thể vào một cổ phiếu thuộc ngành F&B tại thị trường Đông Nam Á – tiêu biểu

là Jollibee – trong giai đoạn hậu đại dịch và suy thoái kinh tế toàn cầu (2024–2025) vẫn còn tương đối hạn chế. Đây là giai đoạn đặc thù, khi hành vi tiêu dùng, chi phí đầu vào và tâm lý nhà đầu tư có nhiều biến động bất thường, khiến cấu trúc chuỗi thời gian tài chính trở nên phức tạp hơn so với các giai đoạn ổn định trước đó.

Bên cạnh đó, phần lớn các nghiên cứu trước đây khi triển khai mô hình lai ARIMA–XGBoost thường tập trung vào việc so sánh hiệu năng tổng thể giữa các mô hình, trong khi các yếu tố kỹ thuật quan trọng ở tầng học máy – đặc biệt là việc lựa chọn và tối ưu hóa “cửa sổ thời gian” (window size) cho XGBoost – lại chưa được phân tích một cách hệ thống. Cửa sổ thời gian đóng vai trò quyết định trong việc cân bằng giữa khả năng khai thác thông tin lịch sử và nguy cơ đưa thêm nhiễu, nhất là đối với dữ liệu tài chính có tính không dừng và biến động cao.

Xuất phát từ khoảng trống nghiên cứu đó, nghiên cứu này hướng đến việc xây dựng và đánh giá mô hình lai ARIMA–XGBoost cho cổ phiếu Jollibee trong giai đoạn 2024–2025, đồng thời tập trung phân tích tác động của kích thước cửa sổ thời gian đến hiệu quả dự báo. Cách tiếp cận này không chỉ góp phần mở rộng bằng chứng thực nghiệm cho mô hình lai trong bối cảnh thị trường Đông Nam Á, mà còn cung cấp góc nhìn kỹ thuật sâu hơn về vai trò của window size – một tham số then chốt nhưng còn ít được khai thác trong các nghiên cứu trước.

PHẦN 3. PHƯƠNG PHÁP NGHIÊN CỨU (METHODOLOGY)

3.1. KHUNG PHÂN TÍCH ĐỀ XUẤT (PROPOSED FRAMEWORK)

Nghiên cứu áp dụng phương pháp luận hai giai đoạn (Two-stage methodology) dựa trên nguyên lý phân rã chuỗi thời gian (Time-series Decomposition). Khung phân tích này được thiết kế để giải quyết bài toán cốt lõi: sự tồn tại đồng thời của các thành phần tuyến tính và phi tuyến trong biến động giá cổ phiếu Jollibee.

Quy trình tổng thể bao gồm 4 giai đoạn chính, được minh họa như sau:

1. **Giai đoạn Tiền xử lý (Preprocessing):** Thu thập dữ liệu thô, làm sạch, xử lý giá trị khuyết và chuyển đổi định dạng chuỗi thời gian.
2. **Giai đoạn 1 - Lọc tuyến tính (Linear Filtering):** Sử dụng mô hình ARIMA để nắm bắt xu hướng chủ đạo và tính mùa vụ. Kết quả quan trọng nhất của giai đoạn này không chỉ là dự báo giá, mà là việc trích xuất **Chuỗi phần dư (Residual Series)** – đại diện cho phần thông tin mà mô hình tuyến tính thất bại trong việc giải thích.
3. **Giai đoạn 2 - Mô hình hóa sai số (Error Modeling):** Sử dụng thuật toán XGBoost để học các quy luật vận động của chuỗi phần dư. Đây là bước cải tiến quan trọng, coi sai số quá khứ là một nguồn dữ liệu đầu vào có giá trị (data input) thay vì loại bỏ.
4. **Giai đoạn 3 - Tổng hợp và Dự báo (Ensemble & Forecasting):** Kết hợp kết quả từ hai mô hình để tạo ra dự báo cuối cùng theo cơ chế cộng (additive model).

3.2. THU THẬP VÀ XỬ LÝ DỮ LIỆU

3.2.1. Nguồn dữ liệu và Phạm vi

Dữ liệu lịch sử giá cổ phiếu Jollibee Foods Corporation (Mã: JBFCF) được thu thập từ cơ sở dữ liệu của **Yahoo Finance** thông qua thư viện `yfinance` trong Python.

- **Dữ liệu đầu vào:** Giá Đóng cửa (Close), Mở cửa (Open), Cao nhất (High), Thấp nhất (Low), và Khối lượng (Volume).
- **Biến mục tiêu (Target Variable):** Nghiên cứu tập trung vào mô hình đơn biến (univariate), do đó chỉ sử dụng **Giá Đóng cửa (Close Price)** làm biến mục tiêu phân tích.
- **Giai đoạn:** Từ **01/01/2024** đến **18/12/2025**.
- **Tổng quan mẫu:** Dữ liệu gốc bao gồm 494 ngày giao dịch trải dài trên 716 ngày lịch.

3.2.2. Kỹ thuật Tiền xử lý (Data Preprocessing)

Trong thực tế, dữ liệu tài chính thường không liên tục do sự gián đoạn bởi các ngày nghỉ cuối tuần và lễ tết. Tuy nhiên, các mô hình chuỗi thời gian lại yêu cầu dữ liệu có tính liên tục theo thời gian để tính toán các độ trễ (lags) một cách chính xác. Vì vậy, dữ liệu cần được xử lý trước nhằm đảm bảo tính liên tục về mặt thời gian (time continuity).

Cụ thể, quy trình tiền xử lý được thực hiện theo hai bước chính. Thứ nhất, dữ liệu được tái lấy mẫu (resampling) về tần suất “ngày làm việc” (Business Day – ký hiệu ‘B’) để chuẩn hóa trục thời gian. Thứ hai, các giá trị bị khuyết phát sinh trong quá trình tái lấy mẫu được xử lý bằng phương pháp điền trước (Forward Fill – ffill).

Cách tiếp cận này có cơ sở lý luận rõ ràng trong tài chính: khi thị trường không có giao dịch vào các ngày nghỉ, mức giá hợp lý nhất của tài sản tại thời điểm đó chính là giá đóng cửa của phiên giao dịch gần nhất trước đó. So với các phương pháp nội suy như nội suy tuyến tính, forward fill giúp bảo toàn cấu trúc xu hướng và động học giá, tránh tạo ra các biến động giả không phản ánh hành vi thực của thị trường.

Sau bước làm sạch và chuẩn hóa, bộ dữ liệu thu được gồm 513 quan sát liên tục theo ngày làm việc và không còn giá trị thiếu (null), sẵn sàng cho các bước phân tích và mô hình hóa tiếp theo.

3.3. GIAI ĐOẠN 1: MÔ HÌNH HÓA TUYẾN TÍNH VỚI ARIMA

Mô hình ARIMA được xây dựng theo quy trình chuẩn Box-Jenkins gồm 3 bước: Kiểm định tính dừng, Xác định tham số và Kiểm định mô hình.

3.3.1. Kiểm định tính dừng (Stationarity Test)


Tính dừng của chuỗi thời gian được kiểm tra bằng kiểm định Augmented Dickey–Fuller (ADF), với giả thuyết gốc H_0 cho rằng chuỗi tồn tại nghiệm đơn vị, tức là không dừng. Theo quy ước thống kê, nếu giá trị p -value lớn hơn 0,05 thì không đủ cơ sở để bác bỏ H_0 , khi đó chuỗi được xem là không dừng và cần được xử lý bằng sai phân. Ngược

lại, nếu p -value nhỏ hơn 0,05, giả thuyết H_0 bị bác bỏ và chuỗi được kết luận là dừng.

3.3.2. Lựa chọn tham số cấu trúc (Model Selection)

Việc xác định bậc tự hồi quy p và trung bình trượt q được thực hiện bằng cách kết hợp hai phương pháp bổ trợ lẫn nhau nhằm đảm bảo lựa chọn mô hình tối ưu và ổn định.

Thứ nhất, phương pháp phân tích trực quan (visual inspection) được áp dụng thông qua việc quan sát dạng tắt dần của các biểu đồ hàm tự tương quan (ACF) và tự tương quan riêng phần (PACF) của chuỗi đã được sai phân. Cách tiếp cận này giúp hình dung sơ bộ cấu trúc phụ thuộc theo độ trễ của chuỗi sau khi đã được sai phân.



Hình 3. 1 Biểu đồ ACF và PACF của chuỗi sai phân giá đóng cửa

Song song với đó, nghiên cứu triển khai phương pháp tìm kiếm lưới (grid search) bằng cách ước lượng hàng loạt mô hình ARIMA với các tổ hợp tham số (p,d,q) , trong đó $p \in [0, 6]$, $d=1$ và $q \in [0, 5]$. Các mô hình được so sánh dựa trên chỉ số thông tin Bayesian (Bayesian Information Criterion – BIC), và mô hình có giá trị BIC nhỏ nhất sẽ được lựa chọn.

Việc ưu tiên BIC thay vì AIC xuất phát từ đặc tính phạt mạnh hơn đối với độ phức tạp mô hình. Điều này giúp đảm bảo lựa chọn được mô hình có cấu trúc gọn nhẹ (parsimonious), hạn chế nguy cơ quá khớp – một yêu cầu quan trọng khi ARIMA đóng vai trò nền tảng trong kiến trúc mô hình lai.

Đồng thời, nhóm cũng sử dụng `auto_arima` từ thư viện `pmdarima`, một thư viện giúp tìm kiếm các tham số (p,d,q) một cách tự động.

Sau khi tìm được tham số mô hình phù hợp, nhóm tiếp tục đánh giá mức độ ổn định của mô hình thông qua kiểm định tính khả nghịch của mô hình và kiểm định phần dư (residual) để xem phần dư có là chuỗi dừng và không có tự tương quan hay không.

3.3.3. Trích xuất Phần dư (Residual Extraction)

Sau khi mô hình ARIMA(1,1,1) được huấn luyện trên toàn bộ tập dữ liệu huấn luyện, phần dư của mô hình được tính toán để đánh giá thông tin còn lại chưa được ARIMA nắm bắt. Cụ thể, chuỗi phần dư e_t được xác định theo công thức:

$$e_t = Y_t - \hat{L}_t$$

trong đó Y_t là giá trị quan sát thực tế tại thời điểm t , còn $\hat{L}_t$ là giá trị dự báo tương ứng thu được từ mô hình ARIMA. Về mặt bản chất, chuỗi phần dư này phản ánh các biến động mà mô hình tuyến tính chưa thể giải thích, bao gồm các cấu trúc phi tuyến và những cú sốc bất thường trong dữ liệu giá.

Trong khuôn khổ nghiên cứu, chuỗi e_t được sử dụng như biến mục tiêu (target variable) cho giai đoạn tiếp theo, nơi mô hình XGBoost được triển khai nhằm khai thác và mô hình hóa các đặc trưng phi tuyến còn tồn tại trong phần dư.

3.4. GIAI ĐOẠN 2: MÔ HÌNH HÓA PHI TUYẾN VỚI XGBOOST

Đây là trọng tâm đóng góp của nghiên cứu, nơi thuật toán học máy được sử dụng để "sửa sai" cho mô hình thống kê.

3.4.1. Kỹ thuật đặc trưng (Feature Engineering)

XGBoost là một thuật toán học có giám sát (supervised learning), do đó yêu cầu dữ liệu đầu vào được biểu diễn dưới dạng ma trận đặc trưng X và biến mục tiêu y . Trong bối cảnh nghiên cứu này, mục tiêu của mô hình là dự báo sai số tại thời điểm t , ký hiệu là et , dựa trên các thông tin đã biết tại thời điểm $t-1$.

Để đáp ứng yêu cầu này, các đặc trưng đầu vào cho XGBoost được xây dựng theo kỹ thuật cửa sổ trượt (sliding window), khai thác chuỗi dự báo ARIMA trong quá khứ. Với độ rộng cửa sổ là k (window size), tại mỗi thời điểm t , mô hình tổng hợp bốn nhóm đặc trưng chính.

Thứ nhất, giá trị dự báo hiện tại từ ARIMA ($\hat{L}_t$) được sử dụng như một đặc trưng nền tảng, phản ánh kỳ vọng tuyến tính của giá tại thời điểm t . Thứ hai, trung bình trượt của k giá trị dự báo liền trước được đưa vào nhằm nắm bắt mức giá kỳ vọng ngắn hạn trong cửa sổ quan sát. Thứ ba, độ lệch chuẩn trượt của cùng tập giá trị dự báo được sử dụng như một đại diện cho mức độ biến động và rủi ro ngắn hạn của thị trường. Cuối cùng, chỉ báo xu hướng được xây dựng thông qua hiệu số giữa giá trị dự báo cuối cùng và đầu tiên trong cửa sổ, cho phép mô hình nhận diện chiều hướng biến động trong ngắn hạn.

Cách xây dựng đặc trưng này giúp XGBoost khai thác đồng thời thông tin về mức giá, độ biến động và xu hướng, qua đó nâng cao khả năng mô hình hóa các thành phần phi tuyến còn sót lại trong phần dư của ARIMA.

3.4.2. Tối ưu hóa Cửa sổ thời gian (Window Size Optimization)

Trong kiến trúc mô hình lai ARIMA–XGBoost, độ rộng cửa sổ k đóng vai trò là tham số then chốt, có ảnh hưởng trực tiếp đến độ chính xác của kết quả dự báo. Giá trị của k quyết định lượng thông tin lịch sử được sử dụng để mô hình hóa phần dư, từ đó tạo ra sự đánh đổi giữa tính ổn định và khả năng phản ứng với các biến động mới của thị trường.

Cụ thể, khi k quá nhỏ, tập đặc trưng chỉ phản ánh một khoảng thời gian rất ngắn, khiến mô hình dễ bị chi phối bởi nhiễu ngẫu nhiên và các dao động nhất thời. Ngược lại, nếu k quá lớn, thông tin trong cửa sổ trở nên quá “dàn trải”, làm giảm độ nhạy của mô hình đối với những thay đổi xu hướng gần đây, đặc biệt trong các giai đoạn thị trường biến động mạnh.

Để xác định giá trị k tối ưu, nghiên cứu tiến hành một quy trình tối ưu hóa dạng vòng lặp, trong đó k được lần lượt thay đổi từ 1 đến 100 ngày giao dịch. Hiệu quả của từng cấu hình được đánh giá dựa trên sai số RMSE trên tập dữ liệu kiểm định.

3.5. CƠ CHẾ DỰ BÁO ĐỆ QUY (RECURSIVE FORECASTING)

Để mô phỏng sát điều kiện giao dịch ngoài thực tế và tránh sai lệch do hiện tượng “nhìn trước tương lai” (look-ahead bias), nghiên cứu áp dụng chiến lược dự báo đệ quy (recursive forecasting) cho tập dữ liệu kiểm tra trong giai đoạn ngoài mẫu (out-of-sample) 30 ngày giao dịch (và 10 ngày giao dịch). Cách tiếp cận này đảm bảo rằng tại mỗi thời điểm dự báo, mô hình chỉ sử dụng các thông tin thực sự sẵn có cho đến thời điểm đó.

Cụ thể, quy trình dự báo được triển khai theo các bước sau. Trước hết, mô hình ARIMA được sử dụng để tạo ra dự báo tuyến tính cho ngày $t+1$, thu được giá trị $\hat{L}_{t+1}$. Tiếp theo, bộ đặc trưng đầu vào cho XGBoost tại thời điểm $t+1$ được xây dựng dựa trên dữ liệu lịch sử cùng với các giá trị dự báo trước đó, sử dụng độ rộng cửa sổ đã tối ưu là 4 ngày.

Sau khi bộ đặc trưng được xác định, mô hình XGBoost tiến hành dự báo phần sai số còn lại tại thời điểm $t+1$, ký hiệu là $\hat{e}_{t+1}$. Dự báo cuối cùng của giá cổ phiếu tại thời điểm này được hình thành bằng cách tổng hợp hai thành phần, bao gồm dự báo tuyến tính từ ARIMA và dự báo phi tuyến từ XGBoost, theo biểu thức:

$$\hat{Y}_{t+1} = \hat{L}_{t+1} + \hat{e}_{t+1}$$

Cuối cùng, giá trị dự báo $\hat{Y}_{t+1}$ được bổ sung vào chuỗi dữ liệu lịch sử giả định và được sử dụng làm đầu vào cho vòng dự báo kế tiếp tại thời điểm $t+2$. Quy trình này được lặp lại liên tục cho đến khi hoàn tất toàn bộ chu kỳ dự báo được yêu cầu.

3.6. TIÊU CHÍ ĐÁNH GIÁ (PERFORMANCE METRICS)

Hiệu quả của mô hình được đánh giá định lượng thông qua ba chỉ số thống kê phổ biến (Hyndman & Athanasopoulos, 2018):

Thứ nhất, **sai số căn bình phương (Root Mean Squared Error – RMSE)** được xác định theo công thức:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$$

RMSE có đặc điểm nhạy cảm với các sai số lớn do bình phương độ lệch giữa giá trị thực tế và giá trị dự báo. Vì vậy, chỉ số này đặc biệt phù hợp trong bối cảnh thị trường chứng khoán, nơi các cú sốc giá mạnh có thể gây ra rủi ro đáng kể cho nhà đầu tư.

Thứ hai, **sai số tuyệt đối trung bình (Mean Absolute Error – MAE)** được tính như sau:

$$MAE = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t|$$

MAE phản ánh mức độ sai lệch trung bình giữa giá trị dự báo và giá trị thực tế theo đơn vị giá gốc (ví dụ: USD). Do không bình phương sai số, MAE ít bị ảnh hưởng bởi các giá trị ngoại lai, qua đó cung cấp một cái nhìn trực quan về độ chính xác trung bình của mô hình.

Cuối cùng, **sai số phần trăm tuyệt đối trung bình (Mean Absolute Percentage Error – MAPE)** được xác định bởi:

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right| \times 100\%$$

MAPE đo lường sai số tương đối dưới dạng phần trăm, cho phép so sánh hiệu quả dự báo giữa các cổ phiếu hoặc thị trường có mức giá khác nhau. Nhờ tính chất chuẩn hóa này, MAPE đặc biệt hữu ích trong các nghiên cứu so sánh đa tài sản.

Việc kết hợp đồng thời ba chỉ số RMSE, MAE và MAPE giúp đảm bảo rằng hiệu quả của mô hình được đánh giá cả về mức độ rủi ro, độ chính xác tuyệt đối và sai số tương đối, từ đó mang lại cái nhìn toàn diện về chất lượng dự báo.

3.7. CÔNG CỤ VÀ MÔI TRƯỜNG NGHIÊN CỨU

Nghiên cứu được thực hiện trên môi trường **Python 3.10**, sử dụng các thư viện mã nguồn mở chuyên dụng:

- pandas, numpy: Xử lý dữ liệu bảng và tính toán ma trận.
- statsmodels, pmdarima: Xây dựng và kiểm định mô hình ARIMA.
- xgboost: Xây dựng mô hình học máy Gradient Boosting.
- sklearn: Tính toán các chỉ số đánh giá (metrics).
- matplotlib, seaborn: Trực quan hóa dữ liệu.

PHẦN 4. EMPIRICAL RESULTS – KẾT QUẢ THỰC NGHIỆM

Sau khi thiết lập khung phương pháp luận tại Chương 3, chương này trình bày các phát hiện thực nghiệm chi tiết. Quá trình phân tích đi từ việc khám phá dữ liệu thô, kiểm định các giả định thống kê, ước lượng mô hình ARIMA, tối ưu hóa mô hình lai ARIMA-XGBoost và cuối cùng là so sánh hiệu quả dự báo để trả lời các câu hỏi nghiên cứu đã đặt ra.

4.1. PHÂN TÍCH DỮ LIỆU SƠ BỘ (EXPLORATORY DATA ANALYSIS - EDA)


4.1.1. Hành vi giá và xu hướng

Quan sát biểu đồ chuỗi thời gian của giá đóng cửa cổ phiếu Jollibee (JBFCF) trong giai đoạn từ tháng 01/2024 đến tháng 12/2025 cho thấy nhiều đặc điểm cấu trúc đáng chú ý. Diễn biến giá không chỉ phản ánh các pha biến động mạnh theo chu kỳ mà còn cho thấy sự thay đổi rõ rệt về trạng thái thị trường giữa hai năm nghiên cứu.

Trong năm 2024, giá cổ phiếu chủ yếu dao động trong một biên độ rộng, từ khoảng 3,50 USD đến 4,75 USD, thể hiện trạng thái đi ngang với mức độ biến động cao (high-volatility sideways). Đáng chú ý, sự xuất hiện của mô hình kỹ thuật “Hai đỉnh” (Double Top) trong giai đoạn này đóng vai trò như một tín hiệu cảnh báo sớm cho khả năng đảo chiều xu hướng trong tương lai.

Sang năm 2025, xu hướng giảm trở nên chiếm ưu thế rõ rệt. Thị trường ghi nhận một cú sụt giảm nhanh ngay từ đầu năm, mang đặc trưng của hiện tượng “flash crash”, sau đó là đợt bán tháo mạnh trong quý IV/2025, khiến giá cổ phiếu rơi về vùng đáy quanh mức 3,00 USD. Những diễn biến này cho thấy mức độ nhạy cảm cao của giá cổ phiếu Jollibee trước các cú sốc thông tin và sự thay đổi trong tâm lý nhà đầu tư.

Tổng thể, dữ liệu giá thể hiện tính không dừng (non-stationarity) rõ ràng về mặt trực quan, khi cả giá trị trung bình lẫn mức độ biến động thay đổi đáng kể theo thời gian. Đặc điểm này củng cố sự cần thiết của các bước xử lý sai phân cũng như việc kết hợp các mô hình tuyến tính và phi tuyến trong khuôn khổ nghiên cứu.



Hình 4. 1 Biểu đồ giá đóng cửa cổ phiếu Jollibee theo thời gian

4.1.2. Kiểm định nghiệm đơn vị (ADF Test)

Kết quả kiểm định ADF cho giá đóng cửa (Close Price) cổ phiếu Jollibee:

Bảng 4. 1 Kết quả kiểm định ADF cho giá đóng cửa cổ phiếu Jollibee

ADF test statistic	-0.865191
--------------------	-----------

p-value	0.799219
Lags used	6.000000
Observations	506.000000
Critical value (1%)	-3.443340
Critical value (5%)	-2.867269
Critical value (10%)	-2.569821

Kết quả thực nghiệm ở bảng trên cho thấy chuỗi giá gốc có p -value bằng 0,799, lớn hơn ngưỡng 0,05, phản ánh rõ ràng tính không dừng của dữ liệu ban đầu. Sau khi thực hiện sai phân bậc nhất, chuỗi ΔP_t cho p -value xấp xỉ bằng 0, cho phép bác bỏ giả thuyết gốc và khẳng định chuỗi đã đạt trạng thái dừng.

Kết quả kiểm định ADF cho chuỗi sai phân giá đóng cửa cổ phiếu Jollibee:

Close Price Diff

Bảng 4. 2 Kết quả kiểm định ADF cho chuỗi sai phân giá đóng cửa cổ phiếu Jollibee


ADF test statistic	-1.400867e+01
p-value	3.747948e-26
Lags used	5.000000e+00
Observations	5.060000e+02
Critical value (1%)	-3.443340e+00

Critical value (5%)	-2.867269e+00
Critical value (10%)	-2.569821e+00

Từ kết quả này, tham số tích hợp của mô hình ARIMA được xác định là $d=1$, phù hợp với đặc trưng phổ biến của dữ liệu giá cổ phiếu trong thực tế.

4.1.3. Phân tích Tự tương quan (ACF và PACF)

Phân tích biểu đồ ACF và PACF của chuỗi sai phân cung cấp những gợi ý quan trọng để lựa chọn tham số ARIMA. Biểu đồ ACF cho thấy một spike âm rõ rệt tại Lag 1 với giá trị khoảng -0.3, sau đó giảm nhanh về gần 0, cho thấy chuỗi có đặc tính Trung bình trượt MA(1). Trong khi đó, PACF thể hiện dạng giảm dần (tailing off), không xuất hiện spike rõ rệt nào vượt ngưỡng, phù hợp với giả thuyết AR thấp hoặc không đáng kể. Hiện tượng tự tương quan âm tại Lag 1 phản ánh cơ chế “Mean Reversion” ngắn hạn: nếu giá hôm nay tăng mạnh, khả năng ngày mai giá sẽ điều chỉnh giảm hoặc tăng yếu hơn là rất cao. Điều này vừa giải thích đặc điểm ngắn hạn của chuỗi, vừa củng cố lựa chọn mô hình ARIMA(1,1,1) với thành phần MA(1) rõ rệt.



Hình 4. 2 Biểu đồ ACF và PACF của chuỗi sai phân giá đóng cửa

4.2. KẾT QUẢ MÔ HÌNH ARIMA

4.2.1. Ước lượng tham số tối ưu

Kết quả Grid Search dựa trên tiêu chí BIC xác định bộ tham số tối ưu cho mô hình ARIMA là $(p, d, q) = (1, 1, 1)$, cân bằng giữa độ chính xác và đơn giản để tránh quá khớp. Hệ số tự hồi quy AR(1) ước lượng được là 0.3082 với $p\text{-value} < 0.001$, cho thấy thành phần AR có ý nghĩa thống kê. Hệ số trung bình trượt MA(1) là -0.7608 với $p\text{-value} < 0.001$, nhấn mạnh vai trò quan trọng của MA trong việc điều chỉnh sai số dự báo và nắm bắt các biến động ngắn hạn.

Đồng thời, phương pháp tìm kiếm sử dụng `auto_arima` cũng cho ra kết quả bộ tham số tương tự.


Bảng 4. 3 Kết quả bộ tham số bằng phương pháp tìm kiếm sử dụng `auto_arima`

Thông số	Giá trị	p-value
AR(1)	0.3082	<0.001
MA(1)	-0.7608	<0.001
σ^2	0.0203	<0.001
Số quan sát	512	—
Log Likelihood	270.910	—
AIC	-535.821	—
BIC	-523.112	—
HQIC	-530.838	—

Ljung-Box Q (L1)	0.04	0.85
Heteroskedasticity H	0.97	0.84
Skew	-2.26	—
Kurtosis	25.84	—

4.2.2. Đánh giá phần dư (Residual Analysis)

Bước đầu tiên trong quy trình đánh giá hiệu suất là xác nhận độ tin cậy của cấu trúc mô hình ARIMA(1,1,1) thông qua vị trí nghiệm của các đa thức đặc trưng. Quan sát biểu đồ *Inverse Roots of ARIMA Polynomials* dưới đây, ta nhận thấy một tín hiệu khả quan khi toàn bộ nghiệm của phần tự hồi quy (AR roots - điểm xanh đặc) và trung bình trượt (MA roots - vòng tròn rỗng) đều nằm gọn hoàn toàn bên trong vòng tròn đơn vị. Về mặt lý thuyết, sự phân bố này là minh chứng toán học quan trọng khẳng định mô hình đã thỏa mãn đồng thời tính dừng (stationarity) và tính khả nghịch (invertibility), đảm bảo quá trình ước lượng diễn ra ổn định, có ý nghĩa thống kê và không xảy ra hiện tượng bùng nổ nghiệm.



Hình 4. 3 Biểu đồ nghiệm nghịch đảo của các đa thức ARIMA

Để củng cố thêm tính vững chắc của mô hình, các kiểm định chẩn đoán trên phần dư (residuals) cũng cho thấy những kết quả rất tích cực về mặt định lượng. Cụ thể, kiểm định Augmented Dickey-Fuller (ADF) xác nhận chuỗi phần dư đã đạt trạng thái dừng với giá trị thống kê $t = -37.90$ và $p\text{-value} = 0.0000$, thấp hơn đáng kể so với mức ý nghĩa 1% (-3.44). Song song với đó, kiểm định Ljung-Box tại độ trễ 10 cho ra $p\text{-value}$ đạt mức $0.977 (> 0.05)$, hàm ý rằng mô hình đã lọc sạch các mối liên hệ tuyến tính, khiến phần dư không còn tồn tại sự tự tương quan đáng kể. Những con số này cho thấy về mặt cấu trúc tuyến tính, ARIMA(1,1,1) đã hoàn thành tốt nhiệm vụ mô hình hóa dữ liệu.

Kết quả kiểm định ADF cho phần dư của mô hình ARIMA(1,1,1):

ARIMA(1,1,1) Residuals

Bảng 4. 4 Kết quả kiểm định ADF cho phần dư của mô hình ARIMA(1,1,1)

ADF test statistic	-37.900733
p-value	0.000000
Lags used	0.000000
Observations	511.000000
Critical value (1%)	-3.443212
Critical value (5%)	-2.867213
Critical value (10%)	-2.569791


Kết quả kiểm định Ljung-Box cho phần dư của mô hình ARIMA(1,1,1):

Bảng 4. 5 Kết quả kiểm định Ljung-Box cho phần dư của mô hình ARIMA(1,1,1)


	lb_stat	lb_pvalue
10	3.171831	0.977086

Tuy nhiên, khi đối chiếu các chỉ số thống kê lý tưởng này với hành vi thực tế trên biểu đồ sai số, ta phát hiện ra những hạn chế mà các kiểm định tiêu chuẩn chưa thể phản

ánh hết. Minh chứng trực quan cho các kết luận kiểm định ở trên được thể hiện đồng nhất qua ba cấp độ biểu đồ so sánh giá thực tế và dự báo. Trên khung thời gian toàn cục, mô hình ARIMA(1,1,1) thể hiện khả năng nắm bắt xu hướng chủ đạo (trend) khá tốt khi đường dự báo bám sát đường giá thực tế. Tuy nhiên, khi đi sâu vào cửa sổ quan sát 100 ngày và đặc biệt là chi tiết 10 phiên gần nhất, điểm yếu về "độ trễ pha" lộ diện rõ rệt: đường dự báo thường xuyên đi sau diễn biến giá thực một nhịp và không vươn tới được các đỉnh/đáy cực đại trong những phiên biến động mạnh (high volatility). Sự lệch pha này giữa đường màu xanh (thực tế) và nét đứt (dự báo) chính là biểu hiện hình học của phần dư phi tuyến còn sót lại, khẳng định rằng ARIMA dù ổn định nhưng chưa đủ nhạy bén với các xung lực ngắn hạn, qua đó củng cố tính cấp thiết của việc áp dụng XGBoost để "học" lại các sai số này nhằm nâng cao độ chính xác dự báo.



Hình 4. 4 Biểu đồ so sánh giá đồng cửa thực tế và giá dự báo của mô hình ARIMA(1,1,1).




Hình 4. 5 Biểu đồ so sánh giá thực tế và giá dự báo trong 10 ngày gần nhất của mô hình $ARIMA(1,1,1)$.

4.3. KẾT QUẢ MÔ HÌNH LAI (HYBRID MODEL)

4.3.1. Tối ưu hóa Window Size cho XGBoost

Việc xác định tham số **Window Size** (số ngày quan sát quá khứ dùng làm đầu vào) đóng vai trò quyết định trong việc tối ưu hóa mô hình phi tuyến XGBoost để dự báo phần dư. Khi nhìn vào biểu đồ dưới đây, có thể thấy rằng:




Hình 4. 6 Biểu đồ tương quan giữa Window Size và Sai số (RMSE)

1. **Sự tối ưu của thông tin ngắn hạn (Short-term Dependency):** Điểm cực tiểu toàn cục (Global Minimum) của sai số dự báo được xác lập rõ ràng tại **Window Size = 4**, với mức RMSE thấp nhất đạt **0.13709**. Kết quả định lượng này khẳng định rằng các biến động của phần dư (residuals) mang tính chất "trí nhớ ngắn hạn" rất mạnh. Mô hình chỉ cần thông tin từ 4 phiên giao dịch gần nhất để giải mã tốt nhất quy luật sai số của ARIMA, thay vì cần một chuỗi dữ liệu dài hơi.
2. **Hiệu ứng "Nhiều tích lũy" (Noise Accumulation):** Trái ngược với kỳ vọng thông thường rằng "nhiều dữ liệu hơn sẽ tốt hơn", biểu đồ cho thấy một xu hướng tăng dần của sai số khi Window Size mở rộng. Đặc biệt, tại các vùng cửa sổ lớn (từ 80 đến 100 ngày), đường RMSE dao động dữ dội với biên độ lớn và đạt các đỉnh sai số cao nhất (lên tới 0.28). Điều này hàm ý rằng việc nạp các dữ liệu quá khứ quá xa (trên 3 tháng) không những không cung cấp thêm "tín hiệu" (signal) có giá trị, mà còn vô tình đưa thêm "nhiều" (noise) vào mô hình, làm phân tán khả năng dự báo chính xác các biến động tức thời.

3. **Cơ sở lựa chọn tham số:** Sự chênh lệch đáng kể về hiệu suất giữa Window Size 4 và các mức cao hơn là cơ sở vững chắc để thiết lập tham số đầu vào cho mô hình lai ghép. Việc chọn Window Size = 4 không chỉ đảm bảo độ chính xác cực đại (minimized RMSE) mà còn giúp mô hình tinh gọn, giảm thiểu chi phí tính toán và tránh hiện tượng quá khớp (overfitting) vào các dữ liệu lịch sử không còn phù hợp (outdated data).

4.3.2. Hiệu quả "Sửa sai" của Mô hình Lai

Việc tích hợp tham số tối ưu Window Size = 4 vào cấu trúc mô hình lai ghép (Hybrid Model) đã mang lại sự cải thiện mang tính bước ngoặt đối với kết quả kiểm nghiệm trên tập dữ liệu mẫu (in-sample).



Hình 4. 7 Biểu đồ kết quả mô hình lai: Dự báo giá cổ phiếu Jollibee trong 30 ngày tới

Quan sát trực quan trên đồ thị cho thấy, đường tín hiệu dự báo của mô hình Hybrid (màu xanh lá) thể hiện khả năng bám sát cực kỳ chặt chẽ so với diễn biến giá thực tế (màu xanh dương). Sự vượt trội này không chỉ dừng lại ở việc nắm bắt xu hướng chung, mà còn thể hiện rõ nét nhất qua khả năng thích ứng tại các vùng nhiễu động mạnh; cụ

thể, ngay cả trong những tình huống thị trường đảo chiều gấp khúc (mô hình đáy chữ V) hay xuất hiện các cú sụt giảm biên độ lớn (flash crash), mô hình vẫn duy trì được độ chính xác cao mà không bị "văng" khỏi quỹ đạo giá.

Sự thành công này đến từ cơ chế bù trừ khiếm khuyết rất hiệu quả giữa hai thành phần của mô hình. Nếu như ARIMA đơn lẻ thường bộc lộ hạn chế cố hữu là phản ứng chậm và trễ nhịp trước các biến động nhanh, thì sự hiện diện của XGBoost đã giải quyết triệt để vấn đề này. Thông qua việc "học" sâu các quy luật vận động phức tạp của phân dư, XGBoost đóng vai trò như một bộ lọc tinh chỉnh, thực hiện cơ chế bù trừ sai số ngay lập tức. Kết quả là tín hiệu dự báo cuối cùng đã đạt được trạng thái gần như đồng pha hoàn toàn với thị trường, khắc phục được độ trễ thời gian (lag) và nâng cao đáng kể độ tin cậy của mô hình trong thực tế.

4.4. SO SÁNH HIỆU QUẢ DỰ BÁO (COMPARATIVE ANALYSIS)


Kết quả thực nghiệm trên tập dữ liệu kiểm tra (Out-of-sample) chính là minh chứng quan trọng nhất khẳng định tính ưu việt của phương pháp lai ghép so với mô hình đơn lẻ. Các số liệu thống kê cho thấy sự cải thiện vượt bậc về độ chính xác dự báo khi tích hợp XGBoost vào quy trình xử lý phân dư.

Bảng 4. 6 Kết quả so sánh hiệu quả dự báo các mô hình

Chỉ số đánh giá (Metric)	ARIMA (Thuần)	Hybrid (ARIMA+XGB)	Mức độ cải thiện (%)
RMSE	0.1426	0.0279	80.44%
MAE	0.0976	0.0208	78.70%

MAPE	2.43%	0.51%	79.03%
-------------	--------------	--------------	---------------

Cụ thể, chỉ số căn bậc hai trung bình bình phương sai số (RMSE) đã giảm một cách ấn tượng từ mức 0.1426 ở mô hình ARIMA thuần xuống chỉ còn 0.0279 ở mô hình Hybrid, tương ứng với mức cải thiện hiệu suất lên tới 80.44%. Xu hướng tích cực này cũng được ghi nhận đồng nhất trên các thước đo khác, khi sai số tuyệt đối trung bình (MAE) giảm sâu về mức 0.0208 và sai số phần trăm trung bình (MAPE) được nén chặt xuống chỉ còn 0.51%, thấp hơn đáng kể so với mức 2.43% ban đầu.



Hình 4. 8 Biểu đồ so sánh sai số RMSE


Xét trên khía cạnh thực tiễn quản trị rủi ro, sự chênh lệch về hiệu suất này mang lại giá trị rất lớn cho nhà đầu tư. Nếu như việc sử dụng ARIMA khiến các quyết định giao dịch phải đối mặt với biên độ sai lệch giá khá rộng, thì mô hình Hybrid giúp thu hẹp "vùng không chắc chắn" này xuống mức tối thiểu, đạt đủ độ tin cậy cần thiết cho các chiến lược giao dịch ngắn hạn (Swing Trading). Sự ổn định này được phản ánh trực quan qua biểu đồ so sánh sai số; trong khi đường lỗi của ARIMA (nét đứt màu xám) dao động dữ dội với biên độ lớn, thì đường lỗi của mô hình Hybrid (màu đỏ) lại thể hiện sự "bình

tính" đáng kinh ngạc khi bám rất sát trục \$0\$ và hiếm khi vượt quá biên độ hẹp. Điều này xác nhận rằng phần lớn các nhiễu động phi tuyến và xung lực thị trường mà mô hình tuyến tính bỏ sót đã được XGBoost nhận diện và xử lý triệt để.

4.5. DỰ BÁO TƯƠNG LAI

4.5.1. Nhận định xu hướng và Hành động giá

Kết quả dự báo định lượng cho thấy cổ phiếu đang bước vào giai đoạn "Phục hồi kỹ thuật" (Technical Rebound) sau chuỗi giảm điểm mạnh trước đó. Thay vì một đà tăng trưởng tuyến tính, hành động giá dự kiến sẽ hình thành cấu trúc "răng cưa" (sawtooth) với các nhịp tăng giảm đan xen. Về mặt tâm lý thị trường, mô hình hành vi này cho thấy nhà đầu tư đã thoát khỏi trạng thái hoảng loạn bán tháo và đang chuyển sang tâm lý thận trọng, tích lũy cổ phiếu tại vùng giá thấp. Đường giá dự kiến sẽ thiết lập vùng hỗ trợ cứng quanh mốc 3.15 USD và nỗ lực kiểm định lại các vùng kháng cự ngắn hạn quanh 3.30 USD.



Hình 4. 9 Biểu đồ kết quả mô hình lai: Dự báo giá cổ phiếu Jollibee trong 10 ngày tới

4.5.2. Phân tích diễn biến chi tiết

Quan sát chuỗi dữ liệu dự báo, thị trường sẽ trải qua những rung lắc đáng chú ý trong dịp lễ cuối năm:

- **Nhịp tăng ngắn hạn:** Giá cổ phiếu dự kiến đạt đỉnh cục bộ vào ngày **22/12** tại mức **3.29 USD**, phản ánh lực cầu bắt đáy sớm.
- **Áp lực điều chỉnh:** Ngay sau đó, áp lực chốt lời ngắn hạn sẽ đẩy giá về vùng thấp nhất của đợt dự báo là **3.15 USD** vào ngày **24/12**.
- **Hồi phục và Tích lũy:** Một nhịp hồi phục mạnh (Pullback) được dự báo xảy ra ngay phiên tiếp theo (25/12) lên mức **3.27 USD**, trước khi cổ phiếu đi vào trạng thái đi ngang (sideway) tích lũy quanh vùng **3.20 USD** để kết thúc năm 2025 và bước sang năm mới 2026.

Bảng 4. 7 Chi tiết giá dự báo 10 ngày tới (USD)

Ngày giao dịch	Giá đóng cửa dự báo (Predicted Close)	Xu hướng trong ngày
2025-12-19	3.2006	Tích lũy
2025-12-22	3.2898	Tăng (Đỉnh ngắn hạn)
2025-12-23	3.2474	Điều chỉnh nhẹ
2025-12-24	3.1503	Giảm (Vùng hỗ trợ/Đáy)
2025-12-25	3.2737	Hồi phục mạnh

2025-12-26	3.1601	Điều chỉnh
2025-12-29	3.2237	Tăng nhẹ
2025-12-30	3.2554	Tăng tiếp diễn
2025-12-31	3.2034	Chốt lời cuối năm
2026-01-01	3.1849	Thận trọng đầu năm

Kết luận: Dữ liệu dự báo gợi ý chiến lược giao dịch phù hợp trong giai đoạn này là "Swing Trading" – canh mua tại các nhịp nhúng xuống vùng 3.15 - 3.16 USD và canh bán lướt sóng khi giá tiệm cận vùng 3.28 - 3.30 USD.

PHẦN 5. CONCLUSION – KẾT LUẬN VÀ HÀM Ý QUẢN TRỊ

5.1. Kết luận về Hiệu quả Mô hình

Nghiên cứu này được khởi xướng với mục tiêu tìm kiếm giải pháp dự báo tối ưu cho biến động giá cổ phiếu Jollibee Foods Corporation (JBFCF) trong bối cảnh thị trường tài chính giai đoạn 2024–2025 đầy thách thức. Thông qua quy trình kiểm định nghiêm ngặt, nghiên cứu đã giải quyết trọn vẹn các câu hỏi đặt ra, khẳng định sự ưu việt của phương pháp luận lai ghép (Hybrid Approach) qua ba điểm cốt lõi:

- **Vượt qua giới hạn của mô hình tuyến tính:** Kết quả thực nghiệm cho thấy mô hình truyền thống ARIMA(1,1,1), dù thỏa mãn các tiêu chuẩn thống kê lý thuyết (tính dừng, tính khả nghịch), nhưng đã thất bại khi ứng dụng thực tế. Với sai số RMSE cao (0.1426) và độ trễ pha (lagging) cố hữu, ARIMA không thể bắt kịp các diễn biến đảo chiều nhanh của thị trường. Điều này chứng minh rằng chuỗi giá cổ phiếu chứa đựng các cấu trúc phi tuyến phức tạp mà các công cụ tuyến tính đơn thuần không thể giải thích.
- **Sức mạnh của kiến trúc lai ghép:** Việc tích hợp thuật toán XGBoost để xử lý phần sai số của ARIMA đã tạo ra bước ngoặt về độ chính xác. Cơ chế "sửa sai" (Error Correction) này đã giúp giảm tới **80.44%** sai số RMSE (từ 0.1426 xuống còn 0.0279). XGBoost đã chứng minh rằng phần dư của ARIMA không phải là "nhiều trắng" vô nghĩa, mà là mỏ dữ liệu giàu thông tin về xung lực và độ biến động, giúp mô hình triệt tiêu độ trễ và bám sát diễn biến thực tế.
- **Tối ưu hóa tham số:** Nghiên cứu đã xác định được "Cửa sổ vàng" (Golden Window Size) là **4 ngày**. Phát hiện này chỉ ra rằng biến động giá Jollibee chịu

ảnh hưởng mạnh bởi "trí nhớ ngắn hạn", và việc sử dụng cửa sổ quan sát hẹp giúp mô hình phản ứng nhanh nhạy hơn, loại bỏ được nhiễu từ các dữ liệu quá khứ xa.

5.2. Hàm ý Quản trị và Khuyến nghị

Từ những minh chứng định lượng về sự chuyển dịch xu hướng được phát hiện bởi mô hình Hybrid, nghiên cứu đề xuất lộ trình hành động cụ thể cho nhà đầu tư trong giai đoạn từ 19/12/2025 đến giữa tháng 02/2026. Bức tranh dự báo 30 ngày chỉ ra một sự **chuyển pha (phase transition)** quan trọng: từ tích lũy sang tăng trưởng.

Giai đoạn 1: Tích lũy và Rung lắc (19/12/2025 – 05/01/2026)

- **Nhận định:** Dữ liệu dự báo cho thấy thị trường sẽ duy trì cấu trúc "răng cưa" (Sawtooth pattern) với các nhịp tăng giảm đan xen trong biên độ hẹp **3.10 – 3.25 USD**. Đây là giai đoạn thử thách tâm lý khi giá liên tục kiểm định lại đáy nhằm loại bỏ các nhà đầu tư thiếu kiên nhẫn trước khi bứt phá.
- **Hành động:** Áp dụng chiến lược "**Gom hàng vùng trũng**". Nhà đầu tư nên tận dụng các nhịp nhúng xuống (đặc biệt quanh ngày 24/12 và 01/01) để tích lũy cổ phiếu tại vùng giá vốn tối ưu **3.10 – 3.18 USD**. Cần tránh tâm lý hoảng loạn (Panic selling) ở các phiên giảm điểm kỹ thuật này.

Giai đoạn 2: Bứt phá và Tăng trưởng (05/01/2026 – 01/02/2026)

- **Nhận định:** Đường dự báo xác nhận một xu hướng tăng giá dứt khoát (Strong Uptrend) bắt đầu từ tuần thứ hai của năm mới. Cổ phiếu dự kiến sẽ phá vỡ vùng kháng cự tâm lý 3.30 USD, thiết lập các đỉnh sau cao hơn đỉnh trước và hướng tới mục tiêu trung hạn **3.45 – 3.50 USD**.
- **Hành động:** Chuyển sang chiến lược "**Nắm giữ xu hướng**" (Trend Following). Khi giá xác nhận vượt mốc 3.30 USD với thanh khoản cải thiện, nhà đầu tư nên ngừng lướt sóng ngắn hạn và tập trung nắm giữ để tối ưu hóa lợi nhuận.

Mặc dù mô hình có độ chính xác cao, nhà đầu tư cần tuân thủ kỷ luật phòng vệ dựa trên các ngưỡng định lượng:

- **Ngưỡng Cắt lỗ (Stop-loss):** Đặt cứng tại **3.00 USD**. Nếu giá xuyên thủng mốc này, kịch bản phục hồi coi như bị vô hiệu hóa (Structural Break).
- **Tư duy Mô hình hóa:** Nhà đầu tư cần thay đổi tư duy, không nên chỉ dựa vào các chỉ báo trễ (như MA) mà cần tham khảo các tín hiệu từ mô hình học máy để tránh rủi ro "bán đúng đáy" hoặc "mua đúng đỉnh". Hãy sử dụng khoảng tin cậy dự báo như một tấm lá chắn rủi ro chủ động cho các quyết định giải ngân.

Tóm lại: Kết quả nghiên cứu không chỉ cung cấp một công cụ dự báo hiệu suất cao mà còn gợi ý một cơ hội đầu tư hấp dẫn: chấp nhận sự rung lắc ngắn hạn trong dịp cuối năm để đón đầu con sóng tăng trưởng lên tới **10-12%** vào đầu năm 2026.

5.3. HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN (LIMITATIONS & FUTURE WORKS)

Mặc dù đạt được độ chính xác cao trong ngắn hạn, nghiên cứu vẫn tồn tại một số hạn chế cần được khắc phục trong các bước phát triển tiếp theo:

1. Hạn chế: Vấn đề của Dự báo đệ quy xa (Long-term Recursive Forecast):
 - Khi thực hiện dự báo cho khung thời gian dài (trên 30 ngày), mô hình sử dụng kết quả dự báo của ngày hôm trước làm đầu vào cho ngày hôm sau. Quá trình lặp lại này khiến phương sai của sai số dự báo có xu hướng giảm dần và hội tụ về 0 (như đã thảo luận về vấn đề std tiến về 0).
 - Hệ quả: Đường dự báo càng về xa càng trở nên "phẳng" (flat line) và hội tụ về giá trị trung bình, làm mất đi khả năng nắm bắt các biến động bất thường trong dài hạn. Do đó, mô hình hiện tại tối ưu nhất cho giao dịch ngắn hạn (Swing Trading T+10).
2. Hướng phát triển tiếp theo:

- Tích hợp biến Vĩ mô (Macroeconomic Variables): Để cải thiện khả năng dự báo dài hạn, cần đưa thêm các biến ngoại sinh vào mô hình XGBoost như: Lãi suất điều hành, Tỷ giá hối đoái (PHP/USD), hoặc Chỉ số lạm phát. XGBoost có khả năng xử lý rất tốt các dữ liệu đa biến này.
- Phân tích cảm xúc (Sentiment Analysis): Thị trường chứng khoán chịu tác động lớn bởi tin tức. Hướng nghiên cứu tiềm năng là sử dụng kỹ thuật Xử lý ngôn ngữ tự nhiên (NLP) để lượng hóa tin tức tài chính thành các điểm số cảm xúc (Sentiment Score) và đưa vào làm biến đầu vào cho mô hình, thay vì chỉ dựa hoàn toàn vào lịch sử giá quá khứ.

TÀI LIỆU THAM KHẢO

1. Almaafi, A., Bajaba, S., & Alnori, F. (2023). Stock price prediction using ARIMA versus XGBoost models: the case of the largest telecommunication company in the Middle East. *International Journal of System Assurance Engineering and Management*.
2. Box, G. E. P., & Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day.
3. Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th ed.). Wiley.
4. Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM.
5. Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383–417.
6. Hajirahimi, Z., & Khashei, M. (2019). Hybrid structures in time series modeling and forecasting: A review. *Engineering Applications of Artificial Intelligence*, 86, 83-106.
7. Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice* (2nd ed.). OTexts.
8. Meher, K., et al. (2024). Stock Price Prediction using Hybrid ARIMA, Random Forest, and Gradient Boosting Models. *BPAS Journals*.
9. Pai, P.-F., & Lin, C.-S. (2005). A hybrid ARIMA and support vector machines model in stock price forecasting. *Omega*, 33(6), 497–505.

10. Pan, M. (2023). A Comparison of ARIMA, LSTM, XGBOOST and Hybrid in Stock Price Prediction. *2023 5th International Conference on Applied Machine Learning (ICAML)*. IEEE.
11. Wang, J., Zhang, J., & Cai, Y. (2024). A Novel Residual Correction Approach Based on a Hybrid GARCH and XGBoost Model. *Academic Journal of Computing & Information Science*, 7(11), 127-134.
12. Wang, Y., & Guo, Y. (2020). Forecasting method of stock market volatility in time series data based on mixed model of ARIMA and XGBoost. *China Communications*, 17(3), 205–221.
13. Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, 50, 159–175.
14. Zhao, Q., Li, H., Liu, X., & Wang, Y. (2025). A hybrid model of multi-head attention enhanced BiLSTM, ARIMA, and XGBoost for stock price forecasting based on wavelet denoising. *Mathematics*, 13(16), 2622.
15. AWS. (2024). *Developing a Hybrid ARIMA-XGBOOST Model for Analysing Mobile Money Transaction Data in Kenya*.
16. Arab Journals Platform. (n.d.). *Comparison of ARIMA, ANN and Hybrid ARIMA-ANN Models for Time Series Forecasting*.
17. GeeksforGeeks. (n.d.). *XGBoost*.
18. Investopedia. (n.d.). *Box-Jenkins Model Explained: Uses, Methodology, and Forecasting*.
19. International Journal of Scientific Research and Engineering Trends (IJSRET). (2024). *ARIMA and XG Boost Stock Market Forecasting: A Review*.

20. Jollibee Foods Corporation. (2024, March 8). *Jollibee Group delivers solid finish to 2023: Record operating profit of Php14.4 billion, up 45%*. Jollibee Group News.
21. MDPI. (2025). *A Hybrid ARIMA-LSTM-XGBoost Model with Linear Regression Stacking for Transformer Oil Temperature Prediction*.
22. Milvus.io. (n.d.). *The Box-Jenkins Methodology*.
23. Mu, H. (n.d.). *Time-series Forecasting with ML: Part 4 Time-series models and why choose them — XGBoost I*. Medium.
24. NCSS Statistical Software. (n.d.). *The Box-Jenkins Method*.
25. Rehal, V. (2023). *Random Walk Model and Stationarity*. Spur Economics.
26. Simply Wall St. (2025). *Jollibee Foods Corporation (PSE:JFC) - Share price, news & analysis*.
27. Towards Data Science. (n.d.). *Understanding the Limitations of ARIMA Forecasting*.
28. TradingView. (2025). *Jollibee Foods Corp. (JFC) stock key stats*.

PHỤ LỤC

1. Các thư viện cần thiết

pandas

numpy

yfinance

matplotlib

seaborn

statsmodels

pmdarima

xgboost

scikit-learn

2. Mẫu dữ liệu gốc

Price	Close	High	Low	Open	Volume
Ticker	JBFCF	JBFCF	JBFCF	JBFCF	JBFCF
Date					
2024-01-02	4.459289	4.469112	4.144978	4.144978	11100
2024-01-03	4.459289	4.459289	4.459289	4.459289	0

2024-01-04	4.557511	4.812889	4.557511	4.812889	1100
2024-01-05	4.400356	4.616445	4.400356	4.616445	500
2024-01-08	4.508400	4.547689	4.400355	4.547689	1100

3. Bảng thống kê mô tả chuỗi giá đóng cửa sau khi đã làm sạch

Mô tả thống kê:

```

count    513.000000
mean      4.126619
std       0.360409
min       3.012263
25%       3.899274
50%       4.106577
75%       4.459289
max       4.787716

```

4. Hàm kiểm định tính dừng

```

def adf_table(series, name):
    """
    Kiểm định tính dừng ADF cho chuỗi dữ liệu và trả về bảng kết quả.
    """
    result = adfuller(series.dropna())
    test_stat = result[0]
    p_value = result[1]
    lags_used = result[2]
    n_obs = result[3]
    critical_vals = result[4]
    table = pd.DataFrame({
        name: [
            test_stat,
            p_value,

```

```

        lags_used,
        n_obs,
        critical_vals['1%'],
        critical_vals['5%'],
        critical_vals['10%']
    ]
}, index=[
    "ADF test statistic",
    "p-value",
    "Lags used",
    "Observations",
    "Critical value (1%)",
    "Critical value (5%)",
    "Critical value (10%)"
])
return table

```

5. Hàm tạo đặc trưng cho XGBoost

Tạo các features từ dự báo của ARIMA

```

def create_features(arima_preds, residuals=None, window_size=5):
    """
    Tạo X từ chuỗi dự báo của ARIMA (arima_preds).
    Tạo y từ chuỗi sai số (residuals)
    """
    X, y = [], []

    vals = arima_preds.values if isinstance(arima_preds, pd.Series) else
arima_preds
    res_vals = residuals.values if isinstance(residuals, pd.Series) and
residuals is not None else residuals
    if len(vals) <= window_size:
        return np.array([]), np.array([])

    for i in range(len(vals) - window_size):

```

```

# Lấy window các giá trị dự báo
window = vals[i : i+window_size]

# Giá trị dự báo hiện tại (tại thời điểm t)
current_pred = vals[i+window_size]

features = []
features.append(current_pred)          # Giá trị dự báo hiện tại
features.append(np.mean(window))      # TB các dự báo gần đây
features.append(np.std(window))       # Std của các dự báo gần đây
features.append(window[-1] - window[0]) # Xu hướng của dự báo

X.append(features)

# Tạo y
if res_vals is not None:
    y.append(res_vals[i+window_size])
return np.array(X), np.array(y) if res_vals is not None else None

def find_best_window(arima_preds, residuals, candidates):
    rmse_scores = []
    valid_candidates = []
    for size in candidates:
        X_curr, y_curr = create_features(arima_preds, residuals,
window_size=size)

        if len(X_curr) < 50:
            continue

        split = int(len(X_curr) * 0.8)
        X_tr, X_val = X_curr[:split], X_curr[split:]
        y_tr, y_val = y_curr[:split], y_curr[split:]

        model = xgb.XGBRegressor(objective='reg:squarederror',
n_estimators=50, max_depth=3, verbosity=0)

```

```

model.fit(X_tr, y_tr)

preds = model.predict(X_val)
rmse = np.sqrt(mean_squared_error(y_val, preds))

rmse_scores.append(rmse)
valid_candidates.append(size)

best_idx = np.argmin(rmse_scores)
best_size = valid_candidates[best_idx]
best_rmse = rmse_scores[best_idx]

print(f"Window Size tốt nhất là {best_size} (RMSE thấp nhất:
{best_rmse:.5f}) ")

# Vẽ biểu đồ
plt.figure(figsize=(12, 6))
plt.plot(valid_candidates, rmse_scores, marker='o', linestyle='--',
color='royalblue', label='RMSE Score')
plt.axvline(best_size, color='red', linestyle='--', label=f'Best
Window: {best_size}')
plt.scatter(best_size, best_rmse, color='red', s=100, zorder=5)
plt.title('Tương quan giữa Window Size và Sai số (RMSE)',
fontsize=14)
plt.xlabel('Window Size (Số ngày quan sát)', fontsize=12)
plt.ylabel('RMSE (Sai số dự báo)', fontsize=12)
plt.legend()
plt.grid(True, linestyle='--', alpha=0.7)
plt.annotate(f'RMSE: {best_rmse:.5f}',
            xy=(best_size, best_rmse),
            xytext=(best_size+2, best_rmse + (max(rmse_scores)-
min(rmse_scores))*0.1)
)
plt.show()

```



```
return best_size
```

6. Vòng lặp dự báo đệ quy

```
def forecast_next_day(arima_results, xgb_model, history_data,
recent_arima_preds, window_size):
    """
    Args:
        history_data: Dữ liệu giá thực tế
        recent_arima_preds: List chứa các giá trị ARIMA dự báo gần đây
    """
    # Update model ARIMA với dữ liệu lịch sử mới nhất
    new_arima = arima_results.apply(history_data)
    arima_pred_val = new_arima.forecast(steps=1).iloc[0]

    # Tạo Feature cho XGBoost
    current_window_preds = recent_arima_preds[-window_size:] +
[arima_pred_val]

    # Tính toán các feature
    window_calc = current_window_preds[:-1] # Lấy window_size phần tử
trước đó
    current_val = current_window_preds[-1] # Giá trị ARIMA hiện tại

    feat_mean = np.mean(window_calc)
    feat_std = np.std(window_calc)
    feat_trend = window_calc[-1] - window_calc[0]

    # X = [Current_Pred, Mean, Std, Trend]
    xgb_input = np.array([[current_val, feat_mean, feat_std,
feat_trend]])
    # XGBoost dự báo sai số
    xgb_error_pred = xgb_model.predict(xgb_input)[0]
```

```

    final_pred = arima_pred_val + xgb_error_pred
    return final_pred, arima_pred_val

def forecast_multi_days(n_days, arima_fit, xgb_reg, current_data,
best_window_size):
    # Khởi tạo lịch sử giá
    history_prices = current_data.copy()

    # Khởi tạo giá dự báo
    recent_arima_preds = list(arima_fit.fittedvalues[-
best_window_size:].values)
    results = []
    for i in range(n_days):
        final, arima_val = forecast_next_day(
            arima_fit,
            xgb_reg,
            history_prices,
            recent_arima_preds,
            best_window_size
        )
        # Xác định ngày
        last_date = history_prices.index[-1]
        next_date = last_date + BusinessDay(1)
        results.append({'Date': next_date, 'Final_Forecast': final})

    # Thêm giá dự báo cuối cùng vào lịch sử giá (Recursive)
    new_row = pd.Series([final], index=[next_date])
    history_prices = pd.concat([history_prices, new_row])

    # Thêm giá ARIMA dự báo vào danh sách dự báo
    recent_arima_preds.append(arima_val)

    return pd.DataFrame(results).set_index('Date')

```